

Predviđanje performansi NFL igrača putem mašinskog učenja

Milan Jovkić
Departman za računarske nauke
Fakultet tehničkih nauka
Novi Sad, Srbija
milan.jovkic@uns.ac.rs

Uroš Petrašković
Departman za računarske nauke
Fakultet tehničkih nauka
Novi Sad, Srbija
petraskovic.uros@uns.ac.rs

Apstrakt – Predviđanje performansi NFL igrača predstavlja ključni izazov u sportskoj analitici, gde ograničenja *salary cap-a* zahtevaju efikasno upravljanje budžetom timova kako bi se postigla konkurentna prednost kroz identifikaciju igrača sa visokim potencijalom. Ovaj projekat rešava problem predviđanja budućih performansi koristeći statističke podatke iz prethodnih sezona, što omogućava bolje odluke u formiranju timova i povećava šanse za pobedu. Istovremeno ima primenu u *fantasy football* industriji vrednoj preko 11 milijardi dolara. Metodologija uključuje prikupljanje podataka sa izvora kao što je *ProFootballReference*, predprocesiranje sa tretmanom nedostajućih vrednosti i outliera, te primenu različitih regresionih modela mašinskog učenja, kao što linearni modeli (*Ridge*, *Lasso*, *ElasticNet*) i stabala odlučivanja (*Random Forest*, *XGBoost*, *LightGBM*), sa optimizacijom hiperparametara kroz *Random Search*, *Grid Search* i *Bayesian Optimization*. Evaluacija se vrši *walk-forward* validacijom kako bi se simulirali realni uslovi bez curenja informacija iz budućih sezona. Glavni rezultati pokazuju da je pozicija TE (*tight end*) najpredvidljivija sa R^2 vrednostima do 0,5, dok su QB (*quarterback*) i RB (*runningback*) teži za modelovanje sa R^2 oko 0,15–0,25, a WR (*wide receiver*) postiže umerene rezultate od 0,33. Nelinearni modeli generalno nadmašuju linearne, posebno kod QB, RB i WR pozicija, dok TE favorizuje regularizovane linearne pristupe. Ovi nalazi ističu značaj poziciono specifičnog modelovanja i naprednih statistika, otvarajući mogućnosti za unapređenje strateških odluka u NFL timovima.

Ključne reči – NFL analitika, predviđanje performansi igrača, mašinsko učenje, regresija

I. UVOD

Predviđanje performansi individualnih igrača u NFL-u (nacionalnoj fudbalskoj ligi) predstavlja značajan izazov u oblasti sportske analitike [1]. Cilj je kvantifikovati budući učinak igrača na osnovu istorijskih statističkih podataka, pri čemu se moraju uzeti u obzir brojni faktori koji utiču na performanse, kao što su povrede, individualni kvalitet, timski sistem, uloga igrača, taktičke promene i kvalitet protivnika. Ovaj problem je posebno relevantan u kontekstu ograničenja *salary cap-a*, koja timovima nameću budžetska ograničenja i zahtevaju precizne procene vrednosti igrača kako bi se optimizovao sastav tima i povećale šanse za uspeh u takmičenju [2].

Praktična motivacija rada je dvoslojna. Prvi sloj je profesionalna primena u klubovima, gde preciznija procena budućeg učinka pomaže pri odlukama o ugovorima, transferima i raspodeli budžeta. Drugi sloj je analitička primena u *fantasy* okruženju, gde su kvantitativni modeli već standardni alat za procenu vrednosti igrača. U oba slučaja poželjno je imati poziciono specifične modele, jer su obrasci performansi različiti za te pozicije.

U ovom radu razvijeni su modeli mašinskog učenja za predviđanje ključnih metrika performansi NFL igrača po pozicijama: QB (*quarterback*), RB (*running back*), WR (*wide*

receiver) i TE (*tight end*). Modeli se oslanjaju na standardne i napredne statistike prikupljene iz prethodnih sezona.

Metodologija obuhvata predprocesiranje podataka, primenu različitih regresionih algoritama, uključujući linearne modele, stabla odlučivanja, optimizaciju hiperparametara i evaluaciju putem *walk-forward* [3] validacije, čime se eliminiše mogućnost curenja informacija iz budućih sezona. Poseban doprinos rada ogleda se u poziciono specifičnom pristupu modelovanju, koji omogućava prilagođavanje statističkim karakteristikama svake pozicije, kao i u fokusu na realne performanse (kao što su osvojeni jardi) umesto na *fantasy* poene. Postojeći radovi uglavnom se bave predviđanjem rezultata timova ili *fantasy* performansi, dok individualne performanse igrača u NFL-u ostaju relativno manje istražene.

U nastavku rada se redom razmatraju: pregled postojeće relevantne literature i pozicioniranje rada u odnosu na prethodna istraživanja (Poglavlje 2), opis korišćenih metoda i pristupa (Poglavlje 3), prezentacija rezultata i njihova diskusija (Poglavlje 4), te zaključna razmatranja sa smernicama za buduća istraživanja (Poglavlje 5).

II. PREGLED POSTOJEĆE RELEVANTNE LITERATURE

U nastavku su predstavljeni radovi koji rešavaju iste ili srodne probleme, sa obrazloženjem na koji način svaki od njih doprinosi ovom istraživanju ili po čemu se predloženi pristup od njih razlikuje.

A. Predviđanje pobeda NFL timova primenom mašinskog učenja

Rad [1] ispituje koliko dobro modeli mašinskog učenja mogu predviđati procenat pobeda NFL timova u poređenju sa *Pythagorean expectation* formulom, tradicionalnim statističkim pristupom zasnovanim na broju postignutih i primljenih poena. Koristeći podatke sa *Pro-Football-Reference.com* za period 2003–2023, autori primenjuju *Random Forest* i neuronsku mrežu na set timskih indikatora koji obuhvata efikasnost dodavanja i trčanja, gubitke lopte i penale.

Ovaj rad doprinosi predloženom istraživanju na dva načina. Prvo, potvrđuje da modeli ML (mašinskog učenja) konzistentno nadmašuju klasične statističke metode u NFL kontekstu, što opravdava primenu istih tehnika na individualnom nivou. Drugo, metodologija zasnovana na statističkim podacima i *feature importance* analizi direktno je primenjena i u ovom radu. Ključna razlika je u granularnosti analize, navedeni rad modeluje tim kao celinu, dok ovaj rad predviđa performanse pojedinih igrača zasebno po pozicijama, što uvodi dodatnu dimenziju složenosti usled međusobne zavisnosti i poziciono-specifičnih metrika.

B. Multi-output regresija za predviđanje atletskih performansi

Elimam i saradnici [4] istražuju predviđanje sedam međusobno povezanih atletskih i tehničkih metrika elitnih rukometašica koristeći *multi-output* regresione modele. Podaci obuhvataju merenja IMU (*Inertial Measurement Unit*) senzora (akceleracija, promene pravca, opterećenje igrača), video anotacije akcija i kontekstualne informacije o utakmicama, ukupno 533 zapisa. Autori upoređuju kNN (*k Nearest Neighbors*) [5], regresiona stabla, *Random Forest* [6] i neuronske mreže u *single-output* i *multi-output* varijantama, uz hronološku evaluaciju koja sprečava curenje informacija iz budućnosti. *Multi-output* pristup ostvaruje veću preciznost od zasebnih modela i značajno kraće vreme računanja, a kNN i *Random Forest* pokazuju najbolje ukupne rezultate.

Metodološki doprinos ovog rada za predloženo istraživanje ogleda se u demonstraciji da istovremeno predviđanje povezanih metrika, umesto zasebnog modelovanja svake, poboljšava performanse modela. U NFL kontekstu, metrike kao što su osvajanje jardi i broj tačdauna nisu nezavisne, pa *multi-output* pristup predstavlja prirodno proširenje metodologije. Pored toga, hronološka evaluacija korišćena u navedenom radu direktno je ekvivalentna *walk-forward* validaciji primenjenoj u ovom istraživanju. Razlika je u izvoru podataka (merenje senzorima nasuprot sezonskim statistikama) i u sportu, ali temeljni principi modelovanja su prenosivi.

C. Poziciono-specifična analiza performansi NFL igrača u fantasy fudbalu

Abadzic i saradnici **Error! Reference source not found.** analiziraju istorijske performanse NFL igrača radi identifikacije top dvanaest kandidata po pozicijama za *fantasy draft*. Podaci su organizovani zasebno za pozicije QB, RB, WR i TE, pri čemu svaka pozicija nosi različite ključne metrike i obrasce performansi. Predviđanja se vrednuju poređenjem sa ostvarenim *fantasy* poenima na kraju sezone, a analiza naglašava da kontekstualni faktori i istorijski trendovi imaju značajnu prediktivnu moć.

Ovaj rad direktno potvrđuje centralnu pretpostavku predloženog istraživanja, performanse NFL igrača nisu homogene i ne mogu se modelovati jedinstvenim pristupom. Pozicija igrača određuje koje su metrike relevantne i kakvi su obrasci varijacije. Poziciono-specifična organizacija podataka i zasebno treniranje modela po pozicijama preuzeto je kao metodološki princip iz navedenog istraživanja i primenjeno je i u ovom radu. Ključna razlika ogleda se u ciljnoj promenljivoj, umesto *fantasy* poena, koji su koji su veštačka mera zasnovana na pravilima igre, ovaj rad predviđa stvarne sportske metrike kao što su osvajanje jardi i broj tačdauna, čime se postiže veća objektivnost i direktna primenljivost rezultata u kontekstu stvarnog upravljanja NFL timovima.

III. METOD

Predložena metodologija zasniva se na poziciono-specifičnom regresionom modelovanju, pri čemu se za svaku od četiri posmatrane pozicije: *quarterback*, *runningback*, *wide receiver* i *tight end*, trenira i evaluira poseban skup modela. Ovakav pristup motivisan je statistički različitim profilima svake pozicije, QB performanse primarno su određene metrikama dodavanja, RB metrikama trčanja, a WR i TE metrikama prijema lopte. Primena jedinstvenog modela za sve

pozicije zanemarila bi ove strukturalne razlike i vodila bi ka lošijim predikcijama.


A. Skup podataka

Podaci (Tabela 1) su prikupljeni sa platforme ProFootballReference.com [8] primenom Python web skrejpера razvijenog u okviru ovog projekta, koji koristi Selenium biblioteku [9] za dinamičku ekstrakciju sadržaja. Pored standardnih statistika (jardi, dodavanja, tačdauni), ekstrahovane su i napredne metrike (*play action yards*, *run pass option yards*, *yards under pressure*...) tamo gde su dostupne. Za poziciju QB su podaci takodje dopunjeni sa NFL Elo statistikama sa istoimenog sajta. Za poziciju WR korišćen je javno dostupan skup podataka sa HuggingFace platforme (SebastianAndreu/24679_NFL_WR_Dataset_2025) [10], koji obuhvata period 2015–2025 i sadrži kontekstualne faktore kao što su vremenski uslovi i tip terena.

Pozicija	Br. Redova	Br. Kolona
QB	845	188
RB	622	115
TE	351	70
WR	5529	102

Tabela 1 Obim data seta

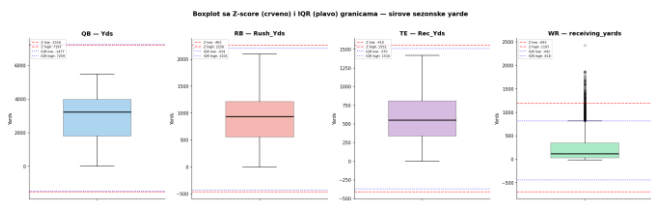
RB i WR podaci prate normalnu distribuciju, dok QB podaci imaju bimodalnu raspodelu, a WR podaci izrazito desno nagnutu distribuciju (Slika 1). U nastavku ćemo opisati transformacije ova 2 seta da bi ih prebacili normalnu distribuciju.



Slika 1 Distribucija ciljnih varijabli

B. Predprocesiranje

Autlajeri su detektovani kombinacijom Z-score metoda [11] (prag $|z| > 3$) i IQR metoda [12] (faktor 1,5). Na sirovim sezonskim jardima, ni Z-score ni IQR ne detektuju autlajere kod QB i RB jer bimodalna (QB) i široka distribucija razvlače standardnu devijaciju i IQR toliko da sve tačke ostaju unutar granica, dok se kod WR pozicije primećuje veliki broj autlajera (Slika 2).




Slika 2 Prikaz autlajera

Kod WR IQR detektuje čak 391 (7%) autlajera, ali to su u stvari legitimni igrači s visokom produkcijom, problem je u desno nagnutoj (*skewed*) distribuciji. To je tzv. Pareto odnos koji je kod pozicije WR zastupljen (Slika 3).



Slika 3 Pareto (Lorenz) kriva

Da bi to rešili primenjujemo log transformaciju na receiving yards, a zatim detektujemo autlajere na log skali. Time su autlajeri iz skupa podataka za WR poziciju eliminisani (Slika 4).




Slika 4 Prikaz autlajera pre i posle log transformacije

QB distribucija ukupnih jardija ima dva vrha (Slika 5), jedan oko 0–500 (rezervni kvoterbeci koji nikad nisu startovali) i drugi oko 3000–4500 (regularni starteri). Rezervni kvoterbeci koji nisu nijednom startovali (GS = 0) nemaju smisleni sezonsku statistiku za predviđanje performansi i trebaju biti isključeni.

Za preostale kvoterbeke (koji su barem jednom startovali), koristimo Yds / G (jardij po odigranoj utakmici) umesto ukupnih sezonskih jardija. Ovo osigurava da igrači koji su se povredili ili propustili deo sezone ne budu nepravedno

klasifikovani kao autlajeri. Uklanjanje 61 QB sezone (GS=0, 7.2%) eliminiše prvi vrh bimodalne distribucije. Preostala distribucija je unimodalna sa blagim levim repom (igrači koji su startovali ali se povredili rano u sezoni). Prelazak na Yds/G dodatno normalizuje tu razliku, sad svaka sezona predstavlja prosečne performanse po utakmici, bez obzira koliko utakmica je igrač propustio (Slika 5).




Slika 5 Prikaz QB distribucije pre i posle y/game transformacije

I za ostale pozicije ciljne promenljive normalizovane su po odigranim utakmicama (*yards/G*) kako bi se eliminisao uticaj povreda i propuštenih utakmica na poređenje između igrača.

U skupovima podataka je pronađen veliki procenat nedostajućih vrednosti i postoje neke kolone koje su potpuno prazne za većinu igrača. Visok procenat *null* vrednosti u ovim kolonama nije greška u podacima, to je posledica prirode same pozicije. Statistike koje za neku poziciju gotovo i ne postoje jednostavno neće biti popunjene. Na primer, QB skupu kolone poput `adv_rr_rec_drop_pct` ili `adv_rr_rec_yac_per_rec` odnose se na receiving metrike, QB praktično nikad nije targetovan kao receiver, pa su te vrednosti *null*. Ove kolone su u skupu podataka prisutne jer se koristi isti šablon kolekcije podataka za sve igrače, ali pri modeliranju će biti isključene ili ignorisane kao nebitne za predviđanje performansi te pozicije.

Drugi vid *null* vrednosti predstavljaju statistike koje nisu postojale u prošlosti. Pro Football Reference je 2018. godine uveo prvi set naprednih *passing* statistika (`adv_pass` kolone). Pre te godine nijedna od ovih kolona nije postojala, pa je prisutnost podataka za sezone pre 2018. ravna 0% tako da su svi redovi *null*. Nakon 2018. većina `adv_pass` kolona je popunjena, što potvrđuje da se radi o strukturalnom nedostatku vezanom za datum uvođenja metrika, a ne o greškama u prikupljanju. Zbog čega ove *advanced* kolone nisu korišćene (Slika 6).

Nakon izbacivanja ovih kolona ostaje jako mali procenat nedostajućih vrednosti koje su popunjene aritmetičkom sredinom ili medijanom, zavisno od oblika distribucije.




Slika 6 Distribucija nedostajućih vrednosti advanced kolona pre 2018.


Sve numeričke promenljive standardizovane su primenom *StandardScaler* transformacije iz *scikit-learn* biblioteke [13],

kako bi se neutralisao uticaj razlika u skali između atributa. Nenumeričke promenljive poput tima i nagrada (*Pro Bowl*, *All-Pro*, MVP - *Most Valuable Player*, OpoY - *Offensive player of the Year*) su zbog malog broja različitih kolona enkodirane pomoću *multi-label binary encoding-a*.

Dodatna observacija su nagle promene u performansama nakon promene tima. Promena sredine često predstavlja ključni faktor za restart ili uspon karijere (Slika 7 i Slika 8).



Slika 7 Tom Brady pre i posle promene tima



Slika 8 Saquon Barkley pre i posle promene tima

Zbog ovakvih situacija je dodata kolona *Team_Changed*, boolean kolona koja ima vrednost 1 ako je igrač promenio tim bas te sezone. Ova kolona pomaže modelu da prepozna situacije gde statistički skok nije slučajan, već je rezultat kvalitetnijeg okruženja i boljeg uklapanja u novi sistem igre.

Takođe, u model uvedene su *Lag* karakteristike sa ciljem uključivanja istorijskih performansi igrača, uz istovremeno izbegavanje curenja podataka iz tekuće sezone. Konkretno, lag1 karakteristike predstavljaju vrednosti iz prethodne sezone ($t-1$), dok lag2 obuhvataju podatke iz sezone ($t-2$). Na ovaj način model dobija uvid u vremenske obrasce i trendove u performansama igrača, što je od ključnog značaja u sportskim analizama, gde su budući rezultati često snažno uslovljeni prethodnim učinkom.

Dodatna prednost ovakvog pristupa jeste što model u svakom trenutku raspolaze isključivo informacijama koje bi realno bile dostupne pre početka nove utakmice ili sezone. Drugim rečima, model vidi samo istorijske podatke i poznate attribute (npr. starost, tim, prethodne statistike), čime se verno simulira stvarna situacija predviđanja i eliminiše mogućnost korišćenja informacija iz budućnosti.

Bez uvođenja lag karakteristika, model bi bio ograničen na statičke osobine igrača, čime bi se izgubila značajna količina informacija o kontinuitetu i formi. U pogledu nedostajućih vrednosti, lag2 karakteristike (za igrače sa kraćom istorijom) popunjavaju se nulama, dok se nedostajuće vrednosti u lag1 atributima imputiraju medijanom. Time se obezbeđuje stabilnost modela i dodatno sprečava potencijalno curenje podataka prilikom predikcije budućih performansi.

C. Primenjeni modeli

Za svaku poziciju primenjeno je sedam kategorija modela, čime je omogućeno sistematično poređenje linearne i nelinearne klase metoda.

Linearni modeli sa regularizacijom Ridge [14], Lasso [15] i ElasticNet [16] proširuju standardnu linearnu regresiju

penalizacijom koeficijenata (L2, L1 i njihovom kombinacijom), čime se smanjuje uticaj multikolinearnosti i poboljšava generalizacija. Prikladni su kao referentne metode kada su odnosi između promenljivih pretežno linearni.

KNN predviđa vrednost ciljne promenljive kao ponderisanu sredinu k najbližijih primera iz trening skupa, mereći sličnost euklidskom distancom u prostoru atributa. Metoda ne pretpostavlja nikakav oblik funkcije regresije, što je čini fleksibilnom, ali osetljivom na irelevantne attribute.

Ansambl metode zasnovane na stablima odlučivanja Random Forest, XGBoost [17] i LightGBM [18] kombinuju veći broj stabala radi hvatanja nelinearnih odnosa i interakcija između promenljivih. Random Forest gradi stabla nezavisno uz *bagging*, dok XGBoost i LightGBM koriste sekvencijalni *boosting* sa gradijentnom optimizacijom greške. Ove metode pogodne su za visokodimenzionalne skupove podataka sa kompleksnom strukturom.

IV. REZULTATI I DISKUSIJA

Cilj eksperimenta bio je utvrditi koji regresioni modeli najefikasnije predviđaju sezonske performanse NFL igrača zasebno po pozicijama.

A. Evaluaciona procedura i metrike

Za evaluaciju su korišćene tri metrike: srednja apsolutna greška MAE za interpretabilnu ocenu prosečnog odstupanja predikcije, koren srednje kvadratne greške (RMSE) koji jače penalizuje velike greške i koeficijent determinacije (R^2) koji izražava proporciju varijanse ciljne promenljive objašnjenu modelom.

Evaluacija svih modela sprovedena je *walk-forward* validacijom, koja simulira realne uslove predviđanja, model se trenira isključivo na podacima koji prethode sezoni koja se predviđa, bez ikakvog pristupa budućim podacima. Konkretno, model se trenira na svim sezonama do godine $t-1$, a zatim evaluira na sezoni t , pri čemu se ova procedura ponavlja za svaku godinu u periodu 2021–2024. Konačne metrike su usrednjene vrednosti kroz sve iteracije. Na ovaj način sprečava se curenje informacija (*data leakage*) koje bi nastalo primenom standardne k-fold unakrsne validacije [19] na vremenskim serijama.

B. Optimizacija hiperparametara

Optimizacija hiperparametara u radu je sprovedena kroz dva odvojena pristupa. Prvi pristup je osnovna optimizacija primenom *Grid Search-a* [13] unutar trening skupa uz 5-fold unakrsnu validaciju, radi dobijanja referentnih rezultata i stabilnog početnog podešavanja modela. Rezultati ovog pristupa, sa optimalnim hiperparametrima po modelu i poziciji, prikazani su u: Tabela 2, Tabela 3, Tabela 4, Tabela 5.

Model	Najbolji parametri
LinearRegression	-
Ridge	{'alpha': 100.0}
Lasso	{'alpha': 1.0}
ElasticNet	{'alpha': 0.1, 'l1_ratio': 0.1}
KNeighbors	{'n_neighbors': 15, 'weights': 'uniform'}
RandomForest	{'max_depth': 5, 'min_samples_split': 2, 'n_estimators': 300}
XGBoost	{'learning_rate': 0.01, 'max_depth': 3, 'n_estimators': 300, 'subsample': 0.8}

Model	Najbolji parametri
LightGBM	{'learning_rate': 0.01, 'max_depth': 3, 'n_estimators': 300, 'num_leaves': 15}

Tabela 2 GirdSearch QB

Model	Najbolji parametri
LinearRegression	-
Ridge	{'alpha': 100.0}
Lasso	{'alpha': 1.0}
ElasticNet	{'alpha': 0.1, 'l1_ratio': 0.1}
KNeighbors	{'n_neighbors': 15, 'weights': 'distance'}
RandomForest	{'max_depth': 5, 'min_samples_split': 2, 'n_estimators': 100}
XGBoost	{'learning_rate': 0.01, 'max_depth': 5, 'n_estimators': 200, 'subsample': 0.8}
LightGBM	{'learning_rate': 0.01, 'max_depth': 3, 'n_estimators': 300, 'num_leaves': 15}

Tabela 3 GridSearch RB

Model	Najbolji parametri
LinearRegression	-
Ridge	{'alpha': 100.0}
Lasso	{'alpha': 1.0}
ElasticNet	{'alpha': 1.0, 'l1_ratio': 0.1}
KNeighbors	{'n_neighbors': 7, 'weights': 'uniform'}
RandomForest	{'max_depth': 5, 'min_samples_split': 2, 'n_estimators': 300}
XGBoost	{'learning_rate': 0.05, 'max_depth': 3, 'n_estimators': 100, 'subsample': 0.8}
LightGBM	{'learning_rate': 0.05, 'max_depth': 3, 'n_estimators': 100, 'num_leaves': 15}

Tabela 4 GridSearch TE

Model	Najbolji parametri
LinearRegression	-
Ridge	{'alpha': 100.0}
Lasso	{'alpha': 1.0}
ElasticNet	{'alpha': 1.0, 'l1_ratio': 0.1}
KNeighbors	{'n_neighbors': 7, 'weights': 'uniform'}
RandomForest	{'max_depth': 5, 'min_samples_split': 2, 'n_estimators': 300}
XGBoost	{'learning_rate': 0.05, 'max_depth': 3, 'n_estimators': 100, 'subsample': 0.8}
LightGBM	{'learning_rate': 0.05, 'max_depth': 3, 'n_estimators': 100, 'num_leaves': 15}

Tabela 5 GridSearch WR

Drugi pristup je prošireni trokorak *pipeline* koji uključuje: (1) *Random Search* [20] za brzo mapiranje prostora pretrage, (2) *Grid Search* u okolini najboljih nasumično pronađenih kombinacija radi finog podešavanja i (3) Baejsijsku optimizaciju [21] za finalno tuniranje hiperparametara. Optimalni hiperparametri dobijeni ovim pristupom prikazani su u: Tabela 6, Tabela 7, Tabela 8 i Tabela 9. Početni opsezi parametara u oba pristupa postavljeni su iskustveno, uz asistanciju LLM agenata i konsultovanje relevantne literature, a zatim dodatno sužavani i prilagođavani prema eksperimentalnim rezultatima.

Model	Najbolji parametri
LinearRegression	-

Model	Najbolji parametri
Ridge	alpha=49.3167
Lasso	alpha=0.9141
ElasticNet	alpha=0.2637, l1_ratio=0.5461
XGBoost	n_estimators=96, max_depth=5, learning_rate=0.01995, subsample=0.7160, colsample_bytree=0.6456
LightGBM	n_estimators=96, max_depth=5, learning_rate=0.01995, num_leaves=49, subsample=0.6456
RandomForest	n_estimators=223, max_depth=14, min_samples_split=9, min_samples_leaf=5

Tabela 6 Trokorak pipeline QB

Model	Najbolji parametri
LinearRegression	-
Ridge	alpha=24.6583
Lasso	alpha=0.4571
ElasticNet	alpha=0.2637, l1_ratio=0.5461
XGBoost	n_estimators=299, max_depth=9, learning_rate=0.00745, subsample=0.5260, colsample_bytree=0.5085
LightGBM	n_estimators=96, max_depth=5, learning_rate=0.01995, num_leaves=49, subsample=0.6456
RandomForest	n_estimators=164, max_depth=25, min_samples_split=3, min_samples_leaf=3

Tabela 7 Trokorak pipeline RB

Model	Najbolji parametri
LinearRegression	-
Ridge	alpha=24.6583
Lasso	alpha=0.4571
ElasticNet	alpha=0.2637, l1_ratio=0.5461
XGBoost	n_estimators=299, max_depth=9, learning_rate=0.00745, subsample=0.5260, colsample_bytree=0.5085
LightGBM	n_estimators=96, max_depth=5, learning_rate=0.01995, num_leaves=49, subsample=0.6456
RandomForest	n_estimators=164, max_depth=25, min_samples_split=3, min_samples_leaf=3

Tabela 8 Trokorak pipeline TE

Model	Najbolji parametri
LinearRegression	-
Ridge	alpha=24.6583
Lasso	alpha=0.4571
ElasticNet	alpha=0.2637, l1_ratio=0.5461
XGBoost	n_estimators=299, max_depth=9, learning_rate=0.00745, subsample=0.5260, colsample_bytree=0.5085
LightGBM	n_estimators=96, max_depth=5, learning_rate=0.01995, num_leaves=49, subsample=0.6456
RandomForest	n_estimators=164, max_depth=25, min_samples_split=3, min_samples_leaf=3

Tabela 9 Trokorak pipeline WR

C. Prikaz rezultata na osnovu različitih parametara

Evaluacija modela izvršena je na test skupu podataka, pri čemu su upoređivane performanse modela sa hiperparametrima dobijenim isključivo putem *Grid Search* metode i modela čiji su parametri optimizovani kroz složeniji pipeline od tri koraka. Dobijeni rezultati ukazuju na to da su

performanse ova dva pristupa veoma slične, bez značajnih odstupanja u ključnim metrikama.

Na osnovu toga može se zaključiti da primena višestepenog *pipeline*-a u ovom konkretnom slučaju ne donosi značajno poboljšanje u odnosu na jednostavniji pristup. Iako *pipeline* omogućava sistematičniju i potencijalno robusniju optimizaciju, u ovom problemu njegova dodatna složenost ne rezultira proporcionalnim dobitkom u performansama. Zbog toga se može smatrati da je ovakav pristup nepotrebno kompleksan i da ne doprinosi efikasnosti modela u meri koja bi opravdala njegovo korišćenje.

Rezultati dobijeni potvrđuju da se performanse modela značajno razlikuju po pozicijama, ali i da nelinearni modeli u većini slučajeva ostvaruju blagu prednost.

Kod QB pozicije najbolji rezultat postiže *XGBoost* ($R^2=0.213$), uz vrlo slične performanse *LightGBM*-a ($R^2=0.203$) i malo lošije performanse *RandomForest*-a ($R^2=0.142$). Ovo potvrđuje da je za kvoterbekove prisutna određena nelinearna struktura u podacima, koju stabla odlučivanja uspješnije hvataju od linearnih modela. Ipak, ukupna objašnjena varijansa ostaje niska (oko 20%), što znači da modeli objašnjavaju relativno mali deo realnog učinka QB igrača. Posebno je primetno da *LinearRegression*, *Ridge* i *ElasticNet* imaju negativan R^2 , što implicira da su lošiji od jednostavne predikcije prosekom (Tabela 10).

Model	Optimization Strategy	MAE	RMSE	R ²
LinearRegression	Grid Search	34.113	45.809	-0.038
Lasso	Grid Search	31.611	44.484	0.021
Lasso	Pipeline	32.322	45.214	-0.011
Ridge	Grid Search	33.319	47.885	-0.134
Ridge	Pipeline	34.353	49.074	-0.191
ElasticNet	Grid Search	33.967	48.599	-0.168
ElasticNet	Pipeline	33.556	47.855	-0.133
KNeighbors	Grid Search	33.148	43.847	0.049
KNeighbors	Pipeline	32.846	43.882	0.047
RandomForest	Grid Search	31.817	41.650	0.142
RandomForest	Pipeline	32.638	42.103	0.123
LightGBM	Grid Search	33.140	41.746	0.138
LightGBM	Pipeline	32.099	40.138	0.203
XGBoost	Grid Search	32.587	41.730	0.139
XGBoost	Pipeline	30.502	39.892	0.213

Tabela 10 QB rezultati modela za različite optimizacione strategije

Kod RB pozicije najbolji model je *LightGBM* ($R^2=0.170$), dok su *RandomForrest* i *kNN* nešto slabiji, ali i dalje konkurentni. Linearni modeli ovde postizu skromne rezultate (maksimalno oko $R^2=0.118$), što ponovo sugerise prisustvo kompleksnih interakcija među atributima. Ipak, kao i kod QB pozicije, ukupna predvidljivost ostaje ograničena, jer modeli objašnjavaju svega oko 15% varijanse performansi (Tabela 11).

Model	Optimization Strategy	MAE	RMSE	R ²
LinearRegression	Grid Search	19.031	23.421	0.118
Lasso	Grid Search	20.543	24.373	0.045

Model	Optimization Strategy	MAE	RMSE	R ²
Lasso	Pipeline	20.561	24.233	0.056
Ridge	Grid Search	20.345	24.155	0.062
Ridge	Pipeline	20.007	23.929	0.080
ElasticNet	Grid Search	20.116	23.990	0.075
ElasticNet	Pipeline	20.437	24.163	0.062
KNeighbors	Grid Search	19.414	23.935	0.079
KNeighbors	Pipeline	18.779	23.031	0.147
RandomForest	Grid Search	19.114	23.000	0.150
RandomForest	Pipeline	19.411	23.063	0.145
LightGBM	Grid Search	19.444	23.433	0.117
LightGBM	Pipeline	18.959	22.719	0.170
XGBoost	Grid Search	19.402	23.460	0.115
XGBoost	Pipeline	19.774	23.783	0.091

Tabela 11 RB rezultati modela za različite optimizacione strategije

Pozicija TE se jasno izdvaja kao najpredvidljivija u celom skupu podataka. Najbolji rezultat postiže *Lasso* regresija ($R^2=0.451$), što je ujedno i najviša vrednost determinacije među svim pozicijama. Blizu su i *LightGBM* ($R^2=0.420$), *Ridge* ($R^2=0.411$), *Elastic Net* ($R^2=0.411$) i *XGBoost* ($R^2=0.387$). Ovo ukazuje da su ključni faktori performansi kod TE pozicije u izraženijoj linearnoj korelaciji, dok *Lasso* dodatno doprinosi eliminacijom manje značajnih varijabli i smanjenjem *overfitting*-a (Tabela 12).

Model	Optimization Strategy	MAE	RMSE	R ²
LinearRegression	Grid Search	13.616	16.538	0.218
Lasso	Grid Search	11.707	13.850	0.451
Lasso	Pipeline	12.517	14.911	0.364
Ridge	Grid Search	12.122	14.351	0.411
Ridge	Pipeline	12.652	14.916	0.364
ElasticNet	Grid Search	11.770	13.976	0.441
ElasticNet	Pipeline	12.307	14.578	0.392
KNeighbors	Grid Search	12.865	15.763	0.289
KNeighbors	Pipeline	13.565	17.944	0.078
RandomForest	Grid Search	12.487	15.157	0.343
RandomForest	Pipeline	12.456	15.175	0.341
LightGBM	Grid Search	11.787	14.239	0.420
LightGBM	Pipeline	11.376	14.268	0.418
XGBoost	Grid Search	11.951	14.636	0.387
XGBoost	Pipeline	12.066	14.771	0.376

Tabela 12 TE rezultati modela za različite optimizacione strategije

Kod WR pozicije najbolji rezultat ostvaruje *RandomForest* ($R^2=0.325$), dok su *LightGBM* ($R^2=0.315$) i *XGBoost* ($R^2=0.312$) vrlo blizu. Ovde je primetno da i *kNN* model daje solidan rezultat ($R^2=0.299$), što sugerise postojanje lokalnih obrazaca u podacima. Iako su rezultati bolji nego kod QB i RB pozicija, objašnjena varijansa je i dalje umerenog nivoa (oko 30%), što znači da značajan deo performansi i dalje zavisi od faktora koji nisu uključeni u model (Tabela 13).

Model	Optimization Strategy	MAE	RMSE	R ²
LinearRegression	Grid Search	12.241	18.148	0.160
Lasso	Grid Search	12.073	17.988	0.175
Lasso	Pipeline	12.141	18.001	0.174
Ridge	Grid Search	11.980	17.853	0.187
Ridge	Pipeline	12.099	17.943	0.179
ElasticNet	Grid Search	12.056	17.963	0.177
ElasticNet	Pipeline	12.132	17.996	0.174
KNeighbors	Grid Search	12.433	16.994	0.264
KNeighbors	Pipeline	11.707	16.576	0.299
RandomForest	Grid Search	11.414	16.269	0.325
RandomForest	Pipeline	11.459	16.333	0.320
LightGBM	Grid Search	11.444	16.394	0.315
LightGBM	Pipeline	11.427	16.427	0.312
XGBoost	Grid Search	11.469	16.430	0.312
XGBoost	Pipeline	11.436	16.428	0.312

Tabela 13 WR rezultati modela za različite optimizacione strategije

Generalno posmatrano, nelinearni ansambl modeli (*RandomForest*, *XGBoost*, *LightGBM*) dominiraju kod QB, RB i WR pozicija, dok se kod TE pozicije linearni model sa L1 regularizacijom pokazuje kao optimalno rešenje. Ipak, vrednosti R^2 za QB i RB ostaju relativno niske, što potvrđuje da su ove pozicije najteže za precizno modelovanje, verovatno zbog izražene zavisnosti od spoljašnjih faktora koji nisu u potpunosti obuhvaćeni dostupnim atributima.

D. Kalibracija evaluacije

Kalibracija evaluacije u ovom kontekstu odnosi se na primenu *walk-forward* validacije (*cross-year hold-out*) kako bi se simulirali realni uslovi predikcije performansi NFL igrača, gde modeli treniraju isključivo na istorijskim podacima bez curenja informacija iz budućih sezona. Umesto jednog *split*-a (trening pre 2024, test na 2024), koriste se više *fold*-ova: trening do 2020 za test na 2021, do 2021 za 2022, itd., sve do 2024, što omogućava evaluaciju stabilnosti modela preko vremena, identifikaciju eventualnih trendova u performansama i bolju procenu generalizacije na neviđene podatke, izbegavajući optimizam jednokratne evaluacije.

Rezultati dobijeni kroz *rolling expanding window* evaluaciju (trening do 2020, test 2021, zatim progresivno do 2024) potvrđuju stabilnost modela kroz vreme, ali i jasno diferenciraju pozicije po stepenu predvidljivosti.

Kod QB pozicije najbolji prosečan RMSE ostvaruje *XGBoost* (AvgRMSE=51.564, Avg R^2 =0.176), uz vrlo bliske rezultate *LightGBM*-a i *RandomForest*-a. Ipak, vrednosti R^2 variraju po sezonama, dok su 2021. i 2022. relativno solidne (oko 0.30), 2023. beleži pad i čak negativne vrednosti kod većine modela. Ovo ukazuje na izraženu nestabilnost i vremensku varijabilnost performansi QB igrača. Linearni modeli (*Ridge*, *ElasticNet*, *LinearRegression*) ne zaostaju drastično u proseku, ali nijedan model ne prelazi prosečnih 18% objašnjene varijanse, što potvrđuje da QB ostaje veoma težak za dugoročno generalizovano modelovanje (Tabela 14 i Tabela 15).

Model	RMSE_2021	RMSE_2022	RMSE_2023	RMSE_2024	AvgRMSE
ElasticNet	60.11	36.07	69.22	48.60	53.501
KNeighbors	62.57	36.99	74.59	43.85	54.499
Lasso	59.74	34.72	69.53	44.48	52.119
LightGBM	57.10	34.64	73.46	41.75	51.737
LinearRegression	59.87	35.07	66.05	45.81	51.699
RandomForest	57.39	34.90	73.64	41.65	51.893
Ridge	60.49	36.06	69.58	47.89	53.502

Tabela 14 QB RMSE rezultati za walk forward validaciju

Model	R ² _2021	R ² _2022	R ² _2023	R ² _2024	AvgR ²
ElasticNet	0.227	0.216	0.086	-0.168	0.090
KNeighbors	0.163	0.175	-0.062	0.049	0.081
Lasso	0.237	0.273	0.078	0.021	0.152
LightGBM	0.303	0.277	-0.030	0.138	0.172
LinearRegression	0.233	0.258	0.168	-0.038	0.155
RandomForest	0.296	0.266	-0.035	0.142	0.167
Ridge	0.217	0.216	0.076	-0.134	0.094

Tabela 15 QB R² rezultati za walk forward validaciju

Kod RB pozicije situacija je drugačija, najbolji prosečan rezultat postiže *ElasticNet* (AvgRMSE=19.873, Avg R^2 =0.244), praktično izjednačen sa *Ridge* i *LinearRegression* modelima. Zanimljivo je da ovde linearni modeli nadmašuju ansambl metode, što sugeriše stabilniju i linearniju strukturu odnosa između atributa i ciljne promenljive. Ipak, vidi se izražen pad performansi nakon 2021. (R^2 sa 0.58 pada na 0.07-0.17 u narednim sezonama), što može ukazivati na promene u dinamici igre ili distribuciji podataka kroz vreme (Tabela 16 i Tabela 17).

Model	RMSE_2021	RMSE_2022	RMSE_2023	RMSE_2024	AvgRMSE
ElasticNet	14.40	21.57	19.54	23.99	19.873
KNeighbors	15.10	20.82	21.34	23.93	20.298
Lasso	14.85	22.95	20.33	24.37	20.627
LightGBM	15.51	21.84	21.26	23.43	20.510
LinearRegression	14.57	22.06	19.48	23.42	19.883
RandomForest	15.55	21.25	21.05	23.00	20.211
Ridge	14.31	21.46	19.59	24.15	19.882

Tabela 16 RB RMSE rezultati za walk forward validaciju

Model	R ² _2021	R ² _2022	R ² _2023	R ² _2024	AvgR ²
ElasticNet	0.588	0.141	0.171	0.075	0.244
KNeighbors	0.547	0.199	0.011	0.079	0.209
Lasso	0.562	0.027	0.102	0.045	0.184
LightGBM	0.522	0.119	0.019	0.117	0.194
LinearRegression	0.578	0.101	0.176	0.118	0.243
RandomForest	0.520	0.166	0.038	0.150	0.218
Ridge	0.593	0.149	0.166	0.062	0.243

Tabela 17 RB R² rezultati za walk forward validaciju

Pozicija TE se ponovo izdvaja kao najpredvidljivija. Najniži prosečan RMSE ima *Ridge* (AvgRMSE=13.052,

$AvgR^2=0.502$), gotovo identično kao *Lasso*. Vrednosti R^2 su dosledno visoke (0.41–0.67), posebno u sezonama 2022. i 2023. gde prelaze 0.5. Ovo potvrđuje da su performanse TE igrača u snažnoj i stabilnoj linearnoj korelaciji sa izabranim atributima, dok regularizacija ($\alpha=100$) doprinosi boljoj generalizaciji kroz različite vremenske *fold*-ove. Za razliku od QB i RB, ovde je vremenska stabilnost modela znatno izraženija (Tabela 18 i Tabela 19).

Model	RMSE_20_21	RMSE_20_22	RMSE_20_23	RMSE_20_24	AvgRMS E
ElasticNet	15.59	9.66	13.68	13.98	13.227
KNeighbors	17.70	12.81	17.44	15.76	15.930
Lasso	15.15	9.60	13.74	13.85	13.085
LightGBM	14.18	11.85	14.70	14.24	13.743
LinearRegression	21.74	12.07	13.64	16.54	15.996
RandomForest	14.58	11.58	14.90	15.16	14.053
Ridge	15.58	9.34	12.94	14.35	13.052

Tabela 18 TE RMSE rezultati za walk forward validaciju

Model	R ² _2021	R ² _2022	R ² _2023	R ² _2024	AvgR2
ElasticNet	0.387	0.644	0.490	0.441	0.490
KNeighbors	0.209	0.374	0.171	0.289	0.261
Lasso	0.421	0.648	0.486	0.451	0.502
LightGBM	0.492	0.464	0.411	0.420	0.447
LinearRegression	-0.193	0.444	0.493	0.218	0.241
RandomForest	0.463	0.489	0.395	0.343	0.423
Ridge	0.387	0.667	0.544	0.411	0.502

Tabela 19 TE R² rezultati za walk forward validaciju

Kod WR pozicije najbolji prosečan rezultat ostvaruje *LightGBM* ($AvgRMSE=16.414$, $AvgR^2=0.328$), vrlo blizu su *XGBoost* i *RandomForest*. R^2 vrednosti su umerene (0.29–0.40), sa blagim padom u 2024. godini. Ansambl modeli imaju konzistentnu prednost u odnosu na čisto linearne pristupe, što sugeriše postojanje nelinearnih obrazaca u velikom i heterogenom WR skupu (koji je višestruko veći od ostalih pozicija). Ipak, objašnjena varijansa ostaje oko 30%, što znači da značajan deo performansi i dalje zavisi od faktora koji nisu eksplicitno modelovani (Tabela 20 i Tabela 21).

Model	RMSE_20_21	RMSE_20_22	RMSE_20_23	RMSE_20_24	AvgRMS E
ElasticNet	17.64	16.65	15.83	17.96	17.020
KNeighbors	17.14	16.04	16.44	16.99	16.654
Lasso	17.45	16.91	15.82	17.99	17.044
LightGBM	16.91	16.12	16.23	16.39	16.414
LinearRegression	19.22	16.99	15.89	18.15	17.562
RandomForest	17.40	16.52	16.02	16.27	16.552
Ridge	18.42	16.94	16.11	17.85	17.329

Tabela 20 WR RMSE rezultati za walk forward validaciju

Model	R ² _2021	R ² _2022	R ² _2023	R ² _2024	AvgR2
ElasticNet	0.232	0.285	0.405	0.177	0.275
KNeighbors	0.275	0.336	0.358	0.264	0.308
Lasso	0.248	0.262	0.405	0.175	0.273


Model	R ² _2021	R ² _2022	R ² _2023	R ² _2024	AvgR2
LightGBM	0.293	0.330	0.374	0.315	0.328
LinearRegression	0.088	0.255	0.400	0.160	0.226
RandomForest	0.252	0.296	0.391	0.325	0.316
Ridge	0.162	0.260	0.384	0.187	0.248

Tabela 21 WR R² rezultati za walk forward validaciju

E. Vrednost loss funkcije kroz etape

Kretanje *loss* funkcije kroz etape praćeno je isključivo za *XGBoost* i *LightGBM* modele. Razlog tome leži u prirodi ovih algoritama, radi se o sekvencijalnim boosting metodama koje u svakoj etapi dodaju novo stablo i minimizuju grešku na preostalim rezidualima, što omogućava praćenje train i test *RMSE* kroz iteracije. Ostali primenjeni modeli ne poseduju ovu osobinu: linearni modeli (*Ridge*, *Lasso*, *ElasticNet*) imaju zatvoreno analitičko rešenje bez iterativnog treninga, *Random Forest* gradi stabla nezavisno paralelno (*bagging*) bez sekvencijalnog učenja, dok *kNN* uopšte nema fazu treninga u klasičnom smislu.


Analiza je sprovedena za sve četiri pozicije, a kao reprezentativan primer prikazana je pozicija WR. Slika 9 prikazuje tok *loss* funkcije za *XGBoost* i *LightGBM* na WR poziciji. Može se uočiti blagi *underfitting*, train i test krive su bliske jedna drugoj i obe nastavljaju da opadaju do kraja posmatranog broja etapa, bez jasnog minimuma test greške, što ukazuje da modeli nisu dostigli svoj optimalni kapacitet.



Slika 9 Vrednost loss funkcije kroz etape

Na osnovu ovog uvida, broj boosting etapa je povećan, a uvedeno je i *early stopping* kako bi se automatski detektovao optimalan trenutak zaustavljanja treninga. Rezultati su prikazani na Slika 10. Može se uočiti da se *loss* funkcija stabilizovala veoma brzo nakon povećanja broja etapa, a vrednosti greške nisu se značajno promenile u odnosu na prethodni eksperiment. Ovo retroaktivno potvrđuje da je minimum *loss* funkcije bio blizu kraja prvog eksperimenta, te da inicijalni utisak *underfitting-a* nije bio u potpunosti opravdan. Oba modela pokazuju solidnu konvergenciju uz

minimalan *gap* između *train* i test greške, što potvrđuje dobru generalizaciju na neviđenim podacima.



Slika 10 Vrednost loss funkcije kroz etape nakon dupliranja broja epoha

F. Multi output regresija

U kontekstu predikcije performansi NFL igrača, tradicionalni pristup regresije fokusira se na predikciju jedne ciljane promenljive. Međutim, performanse igrača često zavise od više međusobno povezanih metrika koje odražavaju različite aspekte igre. Da bi se ova kompleksnost bolje uhvatila, implementirana je *multi-output* regresija, koja istovremeno predviđa više ciljnih atributa koristeći istu matricu ulaznih karakteristika. Ovaj pristup koristi *native multi-output RandomForestRegressor*, gde se više targeta modeluju zajedno, omogućavajući modelu da uči korelacije između njih i potencijalno poboljša predikciju svakog pojedinačno.

Za poziciju QB, *multi-output* model predviđa *yards_per_game* (prosečan broj jardi po utakmici) i *first_downs_per_game* (prosečan broj prvih down-ova po utakmici). Kod RB pozicije, model predviđa *yards_per_game*, *carries_per_game* (prosečan broj trčanja po utakmici) i *yards_per_attempt* (prosečna efikasnost po pokušaju). Za TE poziciju, se uzimaju *yards_per_game*, *receptions_per_game* (prosečan broj hvatanja po utakmici), *targets_per_game* (prosečan broj targeta po utakmici) i *first_downs_per_game* (prosečan broj prvih down-ova po utakmici). Za WR pozicije, se uzimaju *yards_per_game*, *receptions_per_game* (prosečan broj hvatanja po utakmici), *targets_per_game* (prosečan broj targeta po utakmici), *air_yards_per_game* (prosečan broj vazdušnih jardi po utakmici) i *yac_per_game* (prosečan broj jardi nakon hvatanja po utakmici). Rezultati su prikazani u Tabela 22.

Pozicija	Ciljna varijabla	MAE	RMSE	R2
QB	yards per game	33.661	42.350	0.113

Pozicija	Ciljna varijabla	MAE	RMSE	R2
QB	first downs per game	1.857	2.272	0.259
RB	yards per game	19.675	23.341	0.124
RB	carries per game	3.435	3.992	0.160
RB	yards per attempt	0.503	0.644	0.046
TE	yards per game	12.605	15.275	0.333
TE	receptions per game	1.142	1.417	0.336
TE	targets per game	1.466	1.895	0.349
TE	first downs per game	0.730	0.891	0.360
WR	yards per game	11.726	16.730	0.286
WR	receptions per game	0.848	1.094	0.460
WR	targets per game	1.180	1.532	0.473
WR	air yards per game	13.946	19.724	0.429
WR	yac per game	6.036	8.035	0.359

Tabela 22 Multi output rezultati za sve pozicije

Rezultati *multi-output* regresije za *yards_per_game* kroz sve pozicije ukazuju na konzistentno slabije performanse u poređenju sa *single-output* Random Forest modelima. Ovo sugerise da istovremeno modelovanje više ciljnih varijabli uvodi dodatnu kompleksnost koja može negativno uticati na preciznost predikcije primarne metrike, posebno kada korelacije između *target*-a nisu dovoljno jake ili stabilne.

Kod QB pozicije, vrednost $R^2=0.119$ za *yards_per_game* je niža u odnosu na *single-output* pristup ($R^2=0.142$), što ukazuje da *multi-output* model ne uspeva da kapitalizuje potencijalne međuzavisnosti između metrika. Iako pojedinačne varijable poput *first_downs_per_game* ($R^2=0.270$) pokazuju solidne rezultate, ukupni doprinos *multi-output* pristupa ostaje ograničen, što sugerise da ova pozicija zahteva preciznije specijalizovane modele po *target*-u.

Sličan trend se uočava kod RB pozicije, gde je *yards_per_game* ($R^2=0.124$) ponovo slabiji u odnosu na *single-output* model ($R^2=0.150$). Ipak, *multi-output* pristup pokazuje određenu vrednost kroz bolju predikciju *carries_per_game* ($R^2=0.160$), dok niske vrednosti za *yards_per_attempt* ($R^2=0.046$) ukazuju na to da kompleksnije metrike ostaju izazovne za modelovanje. Ovo potvrđuje da *multi-output* može selektivno doprineti, ali ne pruža univerzalno poboljšanje.

TE pozicija pokazuje solidne rezultate, sa predikcijom *yards_per_game* ($R^2=0.333$) koja je niža od *single-output* Random Forest modela ($R^2=0.404$), ali *multi output* pristup dobro balansira *receptions_per_game* ($R^2=0.336$), *targets_per_game* ($R^2=0.349$) i *first_downs_per_game* ($R^2=0.360$). Ostale varijable doprinose ukupnoj predikciji, pokazujući konzistentnost u prijemnim metrikama, što čini *multi-output* pristup vrednim za ovu poziciju.

Kod WR pozicije, predikcija *yards_per_game* ($R^2=0.286$) je niža od *single-output* Random Forest modela ($R^2=0.325$), ali *multi output* model izvrsno predviđa statistike poput *receptions_per_game* ($R^2=0.460$), *targets_per_game* ($R^2=0.473$), *air_yards_per_game* ($R^2=0.429$) i

yac_per_game ($R^2=0.359$). Ostale varijable pokazuju dobre rezultate, što naglašava važnost dodatnih metrika u heterogenom WR skupu podataka i potencijal *multi-output* pristupa za bolju generalizaciju.

Iz ovoga možemo zaključiti da, u poređenju sa *single-output RandomForest* modelima, *multi-output* pristup pokazuje jasne prednosti u predikciji sekundarnih metrika, posebno kod TE i WR pozicija, ali ne uspeva da nadmaši *single-output* modele u predikciji primarne metrike *yards_per_game* kroz sve pozicije. Ovo ukazuje da izbor pristupa treba prilagoditi ciljevima modelovanja.

V. ZAKLJUCAK

Ovaj rad se bavi problemom predviđanja performansi individualnih NFL igrača primenom metoda mašinskog učenja. Osnovna motivacija za istraživanje proistekla je iz praktičnih potreba NFL timova koji, usled ograničenja *salary cap*-a, moraju donositi precizne odluke pri vrednovanju igrača i upravljanju budžetom.

Problem je rešen razvojem poziciono specifičnih regresionih modela za četiri ključne NFL pozicije: *quarterback*, *running back*, *wide receiver* i *tight end*. Podaci su prikupljeni sa platforme ProFootballReference.com sopstvenim *web* skreperom, a za poziciju WR korišćen je i javno dostupan skup podataka sa *HuggingFace* platforme. Nakon obimnog predprocesiranja, koje je obuhvatalo detekciju i tretman autajera, log transformaciju, normalizaciju ciljnih promenljivih po odigranim utakmicama, imputaciju nedostajućih vrednosti i uvođenje *lag* karakteristika, primenjeno je sedam klasa regresionih modela: linearne metode sa regularizacijom (*Ridge*, *Lasso*, *ElasticNet*), metoda k najbližih suseda (kNN) i ansambl metode zasnovane na stablima odlučivanja (*Random Forest*, *XGBoost*, *LightGBM*). Evaluacija je sprovedena *walk-forward* validacijom koja simulira realne uslove predviđanja bez curenja informacija iz budućih sezona. Pored toga, istražena je i primenljivost *multi-output* regresije za istovremeno predviđanje više međusobno povezanih metrika.

Glavni rezultati pokazuju da se predvidljivost performansi značajno razlikuje po pozicijama. Pozicija TE pokazala se kao najpredvidljivija, sa vrednostima R^2 do 0,50 u *walk-forward* evaluaciji, pri čemu regularizovani linearni modeli (*Ridge* i *Lasso*) ostvaruju najbolje rezultate, što ukazuje na izraženu linearnu strukturu u podacima za ovu poziciju. Pozicija WR postigla je umerene rezultate (R^2 oko 0,33), dok su QB i RB najteži za modelovanje (R^2 oko 0,15–0,25), jer na performanse ovih igrača u velikoj meri utiču faktori koji nisu obuhvaćeni dostupnim atributima, poput kvaliteta saigraca, sistemske prilagodjenosti i situacionih odluka tokom utakmica. Nelinearni ansambl modeli generalno nadmašuju linearne pristupe kod QB, RB i WR pozicija, dok TE favorizuje regularizovane linearne modele. *Multi-output* regresija pokazuje prednosti u predviđanju sekundarnih metrika, posebno kod TE i WR pozicija, ali ne nadmašuje *single-output* pristupe u predikciji primarne metrike (*yards per game*).

Ključne prednosti predloženog rešenja su višestruke. Poziciono specifičan pristup modelovanju - koji se razlikuje od većine postojećih radova koji modeluju igrače kao homogenu grupu - omogućava prilagodjenost statičkim profilima svake pozicije i time ostvaruje tačnije predikcije. Fokus na stvarne sportske metrike (jardi, tačdauni) umesto

fantasy poena čini rešenje objektivnijim i direktno primenljivim u kontekstu profesionalnog upravljanja timovima. Korišćenje *walk-forward* validacije osigurava metodološki integritet i pouzdanost evaluacionih rezultata. Pored toga, uvođenje lag karakteristika i binarnog indikatora promene tima (*Team_Changed*) omogućava modelu da prepozna temporalne obrasce i strukturalne promene u karijeri igrača.

Ipak, postoje i određeni nedostaci koje treba uzeti u obzir. Niske vrednosti R^2 za QB i RB pozicije ukazuju na to da značajan deo varijabilnosti performansi ostaje neobjašnjiv dostupnim atributima. Modeli ne uzimaju u obzir kontekstualne faktore kao što su kvalitet protivničke odbrane, vremenski uslovi (osim delimično kod WR), povređenost igrača i promene trenera ili igračkog sistema, koji mogu imati značajan uticaj na učinak igrača. Takodje, napredne statistike bile su dostupne samo za sezone počev od 2018. godine, što je limitiralo količinu istorijskih podataka za trening i potencijalno smanjilo sposobnost modela da identifikuje duže temporalne obrasce.

Ovaj rad treba pre svega zapamtiti po poziciono specifičnom pristupu modelovanju individualnih performansi NFL igrača, koji demonstrira da različite pozicije zahtevaju različite modelske pristupe, linearne i nelinearne, u zavisnosti od statističke strukture podataka. Takodje, primena *walk-forward* validacije kao rigoroznog evaluacionog okvira koji sprečava curenje podataka iz budućnosti predstavlja metodološki doprinos koji se može direktno preneti na druga vremenska istraživanja u sportskoj analitici.

Praktične primene predloženog rešenja su dvojake. U profesionalnom NFL okruženju, modeli mogu poslužiti kao podrška pri odlučivanju o ugovorima, transferima i raspodeli budžeta u okviru *salary cap* ograničenja. U kontekstu *fantasy football*-a, predikti modeli nude kvantitativnu osnovu za rangiranje igrača i selekciju u *draft* rundama, uz potencijal za ugradnju u automatizovane alate i aplikacije. Oba konteksta mogu direktno koristiti od boljeg razumevanja poziciono specifičnih faktora koji pokreću učinak igrača.

Ovo istraživanje otvara više perspektivnih pravaca za budući rad. Najpre, modeli bi se mogli unaprediti uključivanjem dodatnih kontekstualnih atributa, poput statističkih pokazatelja kvaliteta protivničke odbrane, podataka o povredama i oporavku, karakteristika trenera i igračkog sistema, kao i detaljnih biomehaničkih merenja prikupljenih putem *NextGen Stats* tehnologije. Takvi podaci potencijalno bi značajno povećali prediktivnu moć modela, posebno za pozicije QB i RB koje su se pokazale najtežima za modelovanje.

Drugi pravac budućeg rada tiče se arhitekture modela, a posebno primene metoda dubokog učenja koje su do sada ostale neistražene u ovom istraživanju. Posebno perspektivnim se čini korišćenje rekurentnih neuronskih mreža, konkretno LSTM [22] (*Long Short-Term Memory*) i GRU [23] (*Gated Recurrent Unit*) arhitektura, koje su projektovane upravo za modelovanje sekvencijalnih i vremenskih podataka. Za razliku od trenutnog *lag* pristupa, koji korišćenjem karakteristika iz prethodne jedne ili dve sezone na implicitan način kodira istoriju igrača, LSTM i GRU mogu naučiti složene dugoročne zavisnosti direktno iz sekvence podataka. U kontekstu predviđanja NFL performansi, ove arhitekture bi mogle bolje modelovati koncepte poput forme igrača tokom višegodišnje karijere,

opadanja učinka usled starenja ili postepenog rasta mladih igrača.

Međutim, puna primena LSTM i GRU arhitektura zahteva značajno veći skup podataka od onog korišćenog u ovom radu. Trenutni pristup agregira statistike na nivou čitave sezone, što rezultuje relativno malim brojem uzoraka po igraču, tipično svega nekoliko do desetak sezonskih zapisa u toku aktivne karijere. Rekurentne mreže, da bi naučile stabilne temporalne obrasce, zahtevaju dugačke i guste sekvence podataka, što sezonska granularnost ne može pružiti. Prirodno rešenje ovog problema leži u prelasku sa sezonskih na podatke po pojedinačnim utakmicama.

Treći pravac odnosi se na proširenje evaluacije. Bilo bi korisno testirati razvijene modele na podacima iz različitih perioda NFL istorije, kao i na podacima iz srodnih liga (npr. *Canadian Football League* ili *college football*), kako bi se ispitala prenosivost i robustnost predložene metodologije. Posebno je zanimljivo pitanje da li bi isti pristup dao uporedive rezultate u evropskim sportovima poput fudbalskih ili košarkaških liga, gde su statistički podaci takođe bogati i dobro strukturirani.

Konačno, interesantan otvoreni problem koji je ovo istraživanje otvorilo jeste pitanje optimalne granularnosti predviđanja: da li je bolje graditi posebne modele za svaku poziciju (kao što je učinjeno u ovom radu), ili bi još finija segmentacija - na primer razlikovanje startujućih od rezervnih igrača, ili podešavanje modela prema fazi karijere igrača (uspon, zrelost, kraj karijere) - dovela do značajno boljih rezultata. Odgovori na ova pitanja imaju direktnu praktičnu vrednost i predstavljaju prirodni nastavak istraživanja započetog u ovom radu.

VI. NEURONSKE MREŽE

Predmet ovog poglavlja je primena neuronskih mreža na predviđanje broja *receiving* jardi na nivou pojedinačne utakmice. U odnosu na prethodno poglavlje izmenjena je ciljna promenljiva. Umesto sezonski agregiranih jardi po utakmici, modeluje se broj prijemnih jardi po pojedinačnoj utakmici. Glavni razlog za promenu je obim podataka, neuronske mreže stabilno generalizuju na velikim skupovima podataka, sezonski skup za WR poziciju sadrži 5.529 zapisa. Skup sa pojedinačnim utakmicama obuhvata 46.115 zapisa za 1.719 igrača kroz 11 sezona (2015–2025), čime je obezbeđen dovoljan obim.

Radi obezbeđivanja korektne uporedne osnove, na istom skupu obučeni su i klasični regresioni modeli (*RandomForest*, *XGBoost*, *LightGBM*) iz prethodnog poglavlja. Kao neuronske arhitekture testirani su *multilayer perceptron* (MLP) [24] modeli različitog kapaciteta, rekurentne mreže sa *GRU* i *LSTM* ćelijama. Takođe testirani su ansambli koji kombinuju klasične i neuronske modele. Svi modeli su evaluirani pod istim protokolom.

A. Metodologija i implementacija

Metodološki okvir obuhvata četiri komponente: hronološku podelu podataka, inženjerstvo obeležja, izbor i implementaciju arhitekture, i optimizaciju hiperparametara.

1) Skup podataka i vremenska podela

Korišćen skup sadrži 46.115 zapisa na nivou igrač–utakmica za 1.719 igrača iz sezona 2015–2025, sa 99 originalnih kolona. Ciljna promenljiva je *receiving yards*.

Distribucija je desno asimetrična, sa približno 12% utakmica u kojima je ostvareno 0 jardi.

Podela skupa je striktno hronološka: trening obuhvata sezone 2015–2021 (29.276 uzoraka), validacija sezone 2022–2023 (8.921 uzorak), test sezone 2024–2025 (6.199 uzoraka). Test skup je korišćen isključivo za konačnu evaluaciju. Standardizacija je sprovedena *StandardScaler* transformacijom obučenom na trening skupu, dok su procedure imputacije nedostajućih vrednosti i kodiranja kategoričkih kolona preuzete iz prethodnog poglavlja. Za ciljnu promenljivu primenjene su dve transformacije, $\sqrt{y}$ i $\log(1+y)$, izabrane empirijski na osnovu validacionog MAE-a.

Zbog asimetrije ciljne promenljive uvedena je težinska šema uzoraka oblika $w = 1 + 0,6 * \sqrt{(y / \text{mean}_y)}$, čime su veće vrednosti targeta dobile proporcionalno veći značaj u funkciji gubitka.

2) Inženjerstvo obeležja i kreiranje sekvenci

Nad baznim statističkim obeležjima primenjena je temporalna transformacija: za svako obeležje formirani su *lag* i *rolling* proseci, pri čemu je korišćena *shift(1)* operacija radi sprečavanja curenja informacija. Dodatno su dodata interakciona obeležja (npr. indikator početka sezone, broj nedelja od poslednje utakmice) i *matchup* obeležja, proseci defanzivnih statistika protivnika izračunati isključivo iz prethodnih nedelja u sezoni.

Ukupno je formirano 184 obeležja. Preliminarni eksperimenti pokazali su da pun skup uzrokuje preprilagođavanje neuronskih modela, pa je sproveden korak selekcije kombinovanjem *XGBoost* i *LightGBM* ocena važnosti. Selektovano je 40 obeležja koja pokrivaju 51,8% kumulativne važnosti.

Za rekurentne modele formirane su sekvence po igraču. Svaka sekvenca predstavlja hronološki niz utakmica jednog igrača, po vremenskom koraku čuvaju se 33 sirova *game-level* obeležja, dok 20 statičkih *pregame* obeležja ulazi odvojeno kroz drugu granu modela. Kratke karijere nisu odbacivane, umesto filtriranja primenjen je *padding* sa nulama i *masking* sloj koji ignoriše *padded* korake. Maksimalna dužina sekvence T varirala je u opsegu 5 do 12 utakmica, a finalni izbor T = 12 pokriva medijan dužine karijere uz zadržavanje umerenog udela *padded* koraka.

3) Arhitekture modela

Testirano je pet klasa arhitekture: *MLP*, rekurentne mreže, arhitektura sa pažnjom (*attention*) i ugrađivanjem identiteta igrača, kvantilna regresija i ansambli.

a) Multilayer perceptron

Osnovni *MLP*, čija je arhitektura dobijena *Optuna* optimizacijom [25], prima 40 selektovanih obeležja i prosleđuje ih kroz pet potpuno povezanih slojeva dimenzija [448, 128, 320, 448, 256] sa *ReLU* aktivacijama [26], *LayerNorm* normalizacijom [27] i *dropout*-om 0,5. Izlazni sloj je jedan neuron sa linearnom aktivacijom. Modeli C, D i E uvode dodatne regularizacione mehanizme: *GaussianNoise* [28] sa $\sigma \in [0,05; 0,25]$, *mixup* augmentaciju [29] primera sa $\alpha \in [0,1; 0,4]$ i kompaktniju arhitekturu [320, 384, 192, 128].

b) Rekurentne mreže (GRU i LSTM)

Kao bazni sekvencijalni modeli testirane su dve varijante rekurentnih ćelija, *LSTM* i *GRU*, primenjene nad *sliding window* sekvencama prethodnih utakmica. Inicijalna

arhitektura dobijena je *Optuna* optimizacijom, kojom je definisana polazna referentna konfiguracija.

Na osnovu polaznog modela razvijena je proširena dvoulazna arhitektura (*Improved RNN*), motivisana činjenicom da predikcija učinka *wide receiver*-a ne zavisi isključivo od sekvence prethodnih nastupa, već i od statičkih *pregame* obeležja dostupnih pre početka meča. Sekvencijalna grana prima istorijat prethodnih mečeva sa 33 obeležja, obrađuje ga preko *masking* sloja koji ignoriše *padding* vrednosti, zatim rekurentnog sloja (*LSTM* odnosno *GRU* varijante), praćenog *LayerNorm* slojem i *Dropout* regularizacijom. Paralelno, statička grana prima 20 *pregame* obeležja koja prolaze kroz *GaussianNoise* sloj radi povećanja robusnosti, a potom propuštaju kroz *Dense* sloj, *LayerNorm* i *Dropout*. Izlazi obe grane se konkatenuiraju i prosleđuju završnom *Dense* sloju koji proizvodi tačkastu predikciju. Na ovaj način model istovremeno iskorišćava vremensku dinamiku forme igrača i kontekstualne informacije specifične za predstojeći meč.

c) Pažnja i ugrađivanje identiteta igrača

Najsloženija arhitektura ima tri ulazne grane. Sekvencijalna grana koristi *Bidirectional LSTM* [30] ili *GRU*. Izlaz prolazi kroz prilagođeni *AttentionPool* sloj [31] koji uči težine za sve vremenske korake, uz maskiranje *padded* pozicija. *Embedding* grana mapira identifikator igrača kroz *Embedding* sloj sa L2 regularizacijom 1e-4. Statička grana obuhvata 20 *pregame* obeležja. Izlazi sve tri grane se konkatenuiraju i prolaze kroz završni *Dense* blok.

d) Kvantilna regresija (*MLP Quantile*)

Ovaj model zadržava arhitekturu *MLP-B* osnove, ali završni sloj je proširen na tri izlazna neurona koji istovremeno predviđaju tri kvantila ciljne promenljive: donji (q10), medijanu (q50) i gornji (q90) [32]. Trening se vodi *pinball* funkcijom gubitka, asimetričnom funkcijom koja različito kažnjava potcenjivanje i precenjivanje u zavisnosti od ciljanog kvantila i na taj način usmerava svaki izlaz da aproksimira odgovarajući nivo uslovne distribucije. Kao tačkasta predikcija koristi se medijana q50, koja je robusnija na ekstremne vrednosti od srednje vrednosti. Razlika između gornjeg i donjeg kvantila (q90-q10) direktno definiše 80% interval poverenja, čime model pored same predikcije pruža i kvantifikaciju neizvesnosti, što je posebno značajno u kontekstu predviđanja učinka *wide receiver*-a gde je varijabilnost ishoda iz meča u meč izražena.

e) Strategije ansambliranja

Ideja ansambliranja jeste da se kombinovanjem predikcija više modela dobije stabilnija i tačnija procena, pod pretpostavkom da različiti modeli prave različite greške koje se međusobno poništavaju. Fokus je stavljen na kombinaciju *XGBoost*, *LightGBM* i *MLP Hybrid* modela, čime se objedinjuju dve komplementarne klase: *gradient boosting* stabla koja uspešno hvataju nelinearne interakcije između obeležja i neuronska mreža koja modeluje kontinualne obrasce u podacima. Nad ovim baznim modelima primenjene su četiri strategije agregacije: prosta aritmetička sredina, težinsko usrednjavanje na osnovu validacione greške, ograničena linearna kombinacija sa nenegativnim težinama čiji je zbir jednak jedinici i *Ridge* meta-model treniran nad predikcijama baznih modela.

4) Proces treniranja

Kao optimizator korišćen je *AdamW* [33] sa *weight decay* parametrom u opsegu [1e-4; 5e-3]. Funkcija gubitka je *Huber* [34], sa delta parametrom u opsegu [0,5; 2,0], koja kombinuje kvadratnu osetljivost *MSE*-a oko nule sa linearnom robusnošću *MAE*-a u repu raspodele. Za kvantilnu regresiju primenjena je *pinball loss*.

Regularizacija obuhvata *Dropout* (0,2-0,5), *LayerNorm*, *GaussianNoise* ($\sigma = 0,05-0,25$), *Mixup* augmentaciju ($\alpha \in [0,1; 0,4]$), *weight decay* i L2 regularizaciju *embedding* sloja (1e-4). Veličina *batch*-a varira od 32 do 256. Tokom treninga aktivna su tri *callback*-a: *ModelCheckpoint* (kriterijum *val_loss*), *EarlyStopping* (*patience* 12-30, *restore_best_weights* = True) i *ReduceLROnPlateau* (*factor* = 0,3; *patience* = 5-10; *min_lr* = 1e-5). Reprodukovanje eksperimenata je obezbeđeno fiksiranjem *seed*-ova za *python*, *numpy* i *tensorflow* (*seed* = 42).

5) Optimizacija hiperparametara

Hiperparametarski prostor neuronskih modela obuhvata dubinu mreže, broj jedinica po sloju, *dropout*, *learning rate*, *weight decay*, *batch size*, delta za *Huber loss*, α za *Mixup*, σ za *GaussianNoise*, dužinu sekvence, broj rekurentnih slojeva, opcioni bidirekionalni izbor i izbor *LayerNorm*-a. Primenjena je Bayes-ova optimizacija kroz *Optuna* biblioteku sa *Tree-structured Parzen Estimator* (TPE) [35] *sampler*-om i *MedianPruner*-om za prekidanje neperspektivnih trial-ova nakon najmanje tri epohe. Korišćena konfiguracija je 100 *trial*-ova po modelu, sa objective funkcijom $\min(\text{val MAE})$. Vrednosti hiperparametara su prikazani u Tabela 23

Klasa modela	Hiperparametar	Opseg / Skup vrednosti
MLP	broj slojeva	{2, 3, 4, 5}
MLP	broj jedinica po sloju	[64; 448] (step 64)
MLP	dropout	[0,2; 0,5]
MLP	learning_rate	[5e-5; 5e-3] (log)
MLP	weight_decay	[1e-5; 5e-3] (log)
MLP	Huber delta	[0,5; 3,0] (step 0,5)
MLP	GaussianNoise σ	[0,05; 0,30]
MLP	Mixup α	[0,1; 0,4]
MLP	kvantili (fiksno)	{0,10, 0,50, 0,90}
RNN	tip ćelije	{LSTM, GRU}
RNN	bidirectional	{True, False}
RNN	dužina sekvence T	{4, 6, 8, 12}
RNN	broj rekurentnih slojeva	{1, 2}
RNN	broj jedinica	{64, 96, 128, 192, 256}
RNN	dropout	[0,2; 0,4]
RNN	recurrent_dropout	[0,1; 0,3]
RNN	learning_rate	[5e-5; 3e-3] (log)
RNN	weight_decay	[1e-4; 5e-3] (log)
RNN	sample weight strength	[0,5; 1,0]
RNN	ciljna transformacija	$\sqrt{y}$

Sve klase	batch size	{32, 64, 128}
Sve klase	broj epoha	{150, 200, 500}
Sve klase	EarlyStopping patience	{12, 15, 25, 30}

Tabela 23 Prostor pretrage hiperparametara po klasi arhitektura


B. Rezultati i diskusija

Razvoj je sproveden kroz devet sukcesivnih faza, podeljenih u 25 *Jupyter notebook*-a. Svaka faza je motivisana nalazima prethodne. U nastavku se redom prikazuje hronologija razvoja, sumarni rezultati svih modela, poređenje sa klasičnim referentnim modelima.

1) Bazni modeli i pojava overfit-a

U inicijalnoj fazi razvoja, u objedinjenom *pipeline*-u testiran je širi skup arhitektura sa *Optuna* optimizacijom, čime je omogućeno sistematsko poređenje različitih klasa modela pod istim uslovima. Rezultati su pokazali izraženu hijerarhiju: gradient boosting modeli (*XGBoost*, *LightGBM*) i *RandomForest* dostižu R^2 u opsegu 0,33-0,335, čime se profilisu kao najsnažniji *baseline* pristupi, dok *MLP* ostvaruje $R^2 = 0,316$, a *multi-layer RNN* znatno zaostaje sa $R^2 = 0,216$.

Pored samih metrika, tok treninga neuronskih modela ukazao je na ozbiljan problem prilagođavanja (Slika 11). I *MLP* i *RNN* pokazuju tipičan obrazac *overfit*-a: trening greška brzo i stabilno opada, dok validaciona greška rano stagnira i potom počinje da raste, što signalizira da modeli memorišu trening skup umesto da generalizuju. Razlika od približno 0,12 u R^2 između najboljeg *tree* modela (*LightGBM*) i *RNN*-a otkriva strukturna ograničenja inicijalne *RNN* postavke: previše obeležja po koraku, odsustvo regularizacije prilagođene sekvencijalnim podacima i nepostojanje razdvajanja statičkih od dinamičkih ulaza. Upravo je ova razlika predstavljala motivaciju i polaznu tačku za dalji razvoj, prvenstveno za redizajn rekurentne arhitekture i uvođenje hibridnih *MLP* varijanti sa pojačanom regularizacijom.




Slika 11 Base RNN overfit


2) Smanjenje broja obeležja kao prvi korak protiv overfit-a

Prvi sistematski korak za smanjenje prilagođavanja jeste selekcija obeležja. Kombinovana *XGBoost* i *LightGBM* analiza važnosti pokazala je da od 184 inženjerisanih obeležja, 144 ne nose dodatnu informaciju za neuronske modele zbog visoke korelisanosti sa boljim varijantama (npr. *roll3* i *roll5* verzije iste statistike) Slika 12. Redukcija na 40 obeležja uvećava R^2 *MLP*-a za 0,021 i smanjuje *overfit* gap za 0,01-


0,03 u zavisnosti od modela. *Tree* modeli ne dobijaju značajno na ovoj redukciji zbog ugrađenog mehanizma selekcije (Slika 13, Slika 14).



Slika 12 Feature importance dropoff



Slika 13 XGBoost Loss funkcija kroz epohe za 184 feature-a



Slika 14 XGBoost Loss funkcija kroz epohe za 40 feature-a


3) MLP varijante

Pet kontrolisanih *MLP* varijanti (A-E) izoluje efekat broja obeležja i jačine regularizacije. Model A, dobijen *Optuna* optimizacijom, koristi 184 obeležja sa istom arhitekturom kao Model B (40 obeležja). Razlika u R^2 (0,308 vs 0,329) potvrđuje pozitivan efekat selekcije obeležja. Model C primenjuje kompaktniju arhitekturu (3 sloja [256, 128, 64]) sa *GaussianNoise*(0,2) i *Mixup*($\alpha = 0,3$); postiže najmanji *overfit* gap, uz blago niži R^2 . Model D zadržava arhitekturu Modela B i dodaje *GaussianNoise*(0,15) i *Mixup*(0,2), on rezultuje najnižim MAE-om među kontrolnim *MLP* varijantama (17,83). Model E (*Optuna*, 100 *trial*-ova) bira četiri sloja [320, 384, 192, 128] sa $\sigma = 0,25$ i $\alpha = 0,2$, postiže najbolji balans MAE/ R^2 (17,88; 0,3225).

Kontrolisana serija pokazuje sistematski *trade-off*: veći kapacitet bez regularizacije daje viši R^2 uz viši *MAE*; pojačana regularizacija (*noise* + *mixup* + manja arhitektura) daje niži *MAE* uz blago niži R^2 . Ovaj *trade-off* ostaje konzistentan u kasnijim fazama i utiče na izbor strategije ansambliranja.


4) Redizajn rekurentnih mreža (*Improved RNN*)

Inicijalni rezultati rekurentnih mreža motivisali su redizajn arhitekture. Promene su sledeće: (1) sekvencijalna grana prima 33 sirova *game-level* obeležja umesto 184 *lag* i *roll* inženjerisanih; (2) 20 *pregame* obeležja ulazi odvojeno kroz statičku Dense granu, čime mreža ne mora da održava konstantne vrednosti unutar skrivenog stanja; (3) kratke karijere se ne odbacuju, već se primenjuje padding sa *masking* slojem; (4) arhitektura je ograničena na maksimum dva *LSTM* sloja sa najviše 192 jedinice; (5) *LayerNorm* je obavezan i nije prepušten Optuni; (6) *GaussianNoise* je primenjen samo na statičku granu, jer šum nad *padded* pozicijama u sekvenci narušava detekciju maske. Slika 15 prikazuje *loss* funkciju kroz epohe GRU modela.




Slika 15 GRU smanjenje overfita

Postignute metrike: $MAE = 18,03$; $RMSE = 25,11$; $R^2 = 0,3354$. Rekurentne mreže, koje su u prethodnim fazama bile ubedljivo najslabiji pristup, nakon ovih izmena postaju konkurentne svim ostalim modelima i u tom trenutku razvoja ostvaruju i najveći R^2 među svim testiranim modelima, neznatno iznad *LightGBM*-a ($R^2 = 0,3346$). U odnosu na inicijalni *multi-layer RNN*, R^2 je porastao za 0,1197, a *MAE* smanjen za 1,70 jardi. Direktna *LSTM* vs *GRU* ablacija pokazuje minimalnu razliku (R^2 u opsegu 0,3326–0,3354), iz čega sledi da je odlučujući faktor topologija arhitekture, a ne tip rekurentne ćelije (Slika 16, Slika 17).



Slika 16 LSTM loss funkcija kroz epohe



Slika 17 GRU loss funkcija kroz epohe

5) Pažnja i ugrađivanje identiteta igrača

Naredna iteracija nadograđuje *Improved RNN* dvema komponentama: *AttentionPool* slojem i *Embedding* granom namenjenoj identitetu igrača. *Embedding* grana je uvedena sa idejom da modeluje latentne, vremenski stabilne kvalitete pojedinih igrača (talenat, ulogu u timu, stilske karakteristike) koje sirova *game-level* obeležja ne zahvataju u potpunosti, a koje bi mogle nositi prediktivni signal nezavisan od forme u prethodnim mečevima. Radi provere odnosa između tipa rekurentne ćelije i ciljne transformacije, testirana je kombinatorika $\{LSTM, GRU\} * \{\sqrt{y}, \log(1+y)\}$, a dodatno je razmatrana i dijagnostička varijanta sa relaksiranom regularizacijom. Rezultati su ispod *Improved RNN*-a (najbolji *GRU_sqrt* $R^2 = 0,3236$; relaksirana varijanta *GRU_log1p_v2* $R^2 = 0,3262$), pri čemu svi modeli i dalje rano staju.

Uzrok je dvojak: 49,9% test uzoraka ima *player id* koji se ne pojavljuje u trening skupu, te *embedding* sloj ostaje neefikasan na test skupu; takođe, mali broj utakmica po igraču (medijan ≈ 14) ne pruža dovoljno signala za učenje smislenih *attention* težina. Iz navedenog sledi da *Improved RNN* ostaje najbolji rekurentni model za posmatrani skup. Pažnja i ugrađivanje identiteta ne donose poboljšanje, jer ograničenje nije u kapacitetu modela, već u količini i strukturi raspoloživih podataka.

6) Kvantilna regresija

Kvantilna regresija primenjena je nad istom *MLP-B* osnovom, uz *pinball loss* kao funkciju gubitka koja model usmerava da istovremeno procenjuje više tačaka uslovne distribucije ciljne promenljive. Kao tačkasta predikcija koristi se medijan (q_{50}), dok razmak između gornjeg i donjeg kvantila ($q_{90}-q_{10}$) služi kao 80% intervala poverenja, čime model pored same predikcije pruža i kvantifikaciju neizvesnosti.

Postignute metrike su: $MAE\ q_{50} = 17,76$; $RMSE = 25,60$; $R^2 = 0,3093$; pokrivenost pojasa $q_{10}-q_{90}$ iznosi 78,8% (uz ciljanu vrednost od 80%), a prosečna širina pojasa 59,7 jardi. *MLP Quantile* je time najbolji pojedinačni model po *MAE* metrici i jasno ilustruje da izbor funkcije gubitka može imati značajan efekat na kvalitet predikcije.

7) Strategije ansambliranja

Ansambliranje se u ovom radu primenjuje kao poslednji korak u hijerarhiji modelovanja, sa ciljem da se iskoristi komplementarnost grešaka pojedinačnih modela i postigne niža ukupna greška od bilo kog pojedinačnog pristupa. Kao bazni modeli izabrano je pet arhitektura koje pripadaju različitim familijama: *XGBoost* i *LightGBM* kao gradient *boosting* stabla koja hvataju nelinearne interakcije i prekide,

ElasticNet kao regularizovan linearni model koji obezbeđuje stabilnu globalnu aproksimaciju, *MLP Hybrid* kao neuronski regresor osposobljen za modelovanje kontinualnih obrazaca u podacima, i *MLP Quantile* kao kvantilni procenjivač.

Nad ovim skupom baznih modela primenjene su četiri strategije agregacije. Prosta aritmetička sredina predstavlja najjednostavniju referencu, u kojoj svi modeli dobijaju jednaku težinu. Težinsko usrednjavanje na osnovu validacione greške dodeljuje svakom modelu težinu proporcionalnu recipročnoj vrednosti njegovog validacionog *MAE*, čime se automatski favorizuju tačnije komponente ansambla. Ograničena linearna kombinacija koristi numeričku optimizaciju za određivanje težina koje minimizuju validacionu grešku uz striktne uslove nenegativnosti pojedinačnih težina i jedinične sume. *Ridge* meta-model predstavlja pristup u kojem se predikcije baznih modela koriste kao obeležja za treniranje dodatnog *Ridge* regresora, koji tako može naučiti i fine korekcije pristrasnosti pojedinačnih modela. Sve strategije su evaluirane pod istim validacionim protokolom da bi se izbegla pristrasnost u izboru težina i garantovala uporednost rezultata.

Najbolji rezultat po R^2 metrici među svim testiranim ansamblima ostvaruje kombinacija *XGBoost* + *LightGBM* + *MLP*, sa postignutom vrednošću $R^2 = 0,3384$ na test skupu. Ovaj sastav spaja dva predstavnika gradient boosting familije sa neuronskim regresorom, pri čemu se *boosting* komponente oslanjaju na stablastu logiku i diskretne podele prostora obeležja, dok *MLP* modeluje kontinualne, glatke zavisnosti između ulaza i cilja. Upravo ta strukturna raznorodnost komponenti omogućava da kombinovana predikcija bolje objašnjava varijansu u ciljnoj promenljivoj nego bilo koji pojedinačni model. Ansambl je treniran nad punim skupom od 184 obeležja, čime mu je omogućeno da iskoristi širi spektar signala u odnosu na modele obučene na redukovanom skupu od 40 obeležja, a postignuta vrednost istovremeno predstavlja i gornju granicu R^2 performansi u okviru celokupnog razvoja.

8) Sumarni rezultati i poređenje sa klasičnim referentnim modelima

Tabela 24 prikazuje rezultate ključnih modela razvijenih u okviru ovog rada na test skupu (sezona 2024–2025, 6.199 uzoraka), sortirane po R^2 .

Model	Obeležja	Test MAE	Test RMSE	Test R^2
Ansambl (XGB+LGB+MLP)	184	17,84	25,06	0,3378
LSTM Improved	33+20	18,03	25,11	0,3354
LightGBM	40	17,92	25,155	0,3330
GRU Improved	33+20	18,09	25,16	0,3326
RandomForest	40	17,85	25,17	0,3321
XGBoost	40	17,94	25,185	0,3315
GRU Attention	45+20	18,29	25,28	0,3262
MLP (Model B)	40	18,29	25,32	0,3242
MLP Hybrid (Model D)	40	18,05	25,36	0,3219
MLP Quantile q50	40	17,75	25,60	0,3093
MLP Original (Model A)	184	18,10	25,62	0,3079
Base RNN	184	19,73	27,93	0,2157

Tabela 24 Rezultati neuronskih modela i ansambla na test skupu

Tabela jasno pokazuje izraženu hijerarhiju rezultata na test skupu. Na vrhu se nalazi ansambl *XGB* + *LGB* + *MLP* sa $R^2 = 0,3378$, čime potvrđuje da kombinovanje modela različitih

klasa donosi najstabilnije i najtačnije predikcije, iskorišćavajući komplementarnu prirodu grešaka *tree* modela i neuronskih mreža. Među pojedinačnim modelima, najbolji rezultat po R^2 metrici ostvaruje *LSTM Improved* ($R^2 = 0,3354$), koji nadmašuje sve klasične reference u ovoj evaluaciji i pokazuje da pažljivo redizajnirana rekurentna arhitektura može biti konkurentna najjačim klasičnim metodama na ovom zadatku.

Naredna grupa modela, *LightGBM*, *GRU Improved*, *RandomForest* i *XGBoost*, se nalazi u veoma uskom opsegu (R^2 između 0,3315 i 0,3330), što sugeriše da najjači predstavnici *tree* i neuronskih familija konvergiraju ka sličnom nivou tačnosti i da razlike među njima praktično ulaze u zonu eksperimentalnog šuma. Ova bliskost rezultata je sama po sebi informativna: ukazuje da je dostignut prirodni plafon sposobnosti modela nad raspoloživim obeležjima, i da dodatna poboljšanja verovatno zahtevaju obogaćivanje ulaznog prostora pre nego dalje modelsko refinisanje.

Posebno zapažanje zasluđuje *MLP Quantile* q50, koji ostvaruje najnižu vrednost *MAE* od svih modela (17,75 jardi), uprkos tome što mu je R^2 pri dnu tabele (0,3093). Razlog ove asimetrije leži u prirodi *pinball* funkcije gubitka: medijan-predikcija inherentno minimizuje L1 grešku, ali ne nužno i L2-zasnovane metrike poput R^2 .

Na suprotnom kraju tabele izdvaja se *Base RNN* ($R^2 = 0,2157$), čije performanse značajno zaostaju za ostalim modelima i koji je poslužio kao referentna donja granica u razvoju. Razlika od približno 0,12 u R^2 između baznog *RNN*-a i *LSTM Improved* modela direktno kvantifikuje vrednost sprovedenog redizajna rekurentne arhitekture, razdvajanja statičke i sekvencijalne grane, uvođenja maskiranog *padding*-a, ograničavanja kapaciteta i pažljivog usklađivanja regularizacije.

Dodatno, struktura tabele otkriva i jasan uticaj selekcije obeležja: većina modela u vrhu poretka koristi 40 selektovanih obeležja ili hibridnu kombinaciju sekvencijalnih i statičkih obeležja. Ovaj obrazac potvrđuje da redukcija dimenzionalnosti ulaza, iako smanjuje kapacitet modela, u ovom problemu doprinosi boljoj generalizaciji. U celini, rezultati u Tabela 24 pokazuju da se neuronske mreže i klasični modeli na ovom zadatku ponašaju slično po ključnim metrikama, dok ansambl dodaju skromno, ali konzistentno poboljšanje.

9) Ablacija obeležja

Radi procene minimalnog skupa obeležja dovoljnog za očuvanje prediktivne moći modela, finalni modeli su ponovo obučeni na redukovanim skupovima od 5 i 10 najvažnijih obeležja. Rezultati su prikazani u Tabela 25.

Model	Top 5	Top 10	Top 40
LSTM	0,3217	0,3206	0,3354
LightGBM	0,2741	0,2940	0,3330
GRU	0,3195	0,3192	0,3326
RandomForrest	0,3104	0,3247	0,3321
XGBoost	0,2971	0,3111	0,3315
MLP	0,3176	0,3234	0,3242
MLP Quantile	0,2840	0,2954	0,3093

Tabela 25 Vrednost R^2 u odnosu na ablaciju obeležja

Eksperiment otkriva da već top-5 obeležja zadržava pretežni deo ukupnog informacionog sadržaja, prosečna vrednost R^2 opada za svega 0,025 u odnosu na referentni skup

od 40 obeležja, što ukazuje na visoku koncentraciju prediktivnog signala u malom broju varijabli. Proširenje na top-10 donosi dodatnih 0,015 apsolutnih R^2 jedinica, dok dalji porast na 40 obeležja rezultuje merljivim, ali postepeno sve manjim poboljšanjima. Ovaj obrazac opadajućih prinosa sugerise da se optimalni kompromis između informativnosti i kompaktnosti modela nalazi upravo u okolini top-40 skupa, dovoljno malo da se izbegne uvođenje šuma i suvišnih varijabli, a dovoljno veliko da se ne izgubi značajan deo prediktivne moći. Navedeni rezultati istovremeno potvrđuju ispravnost pristupa selekcije obeležja zasnovanog na ansamblu stablovitih modela.

10) Teorijski plafon i ceiling analiza

Jedno od centralnih pitanja ovog istraživanja jeste tumačenje same vrednosti R^2 od 0,33 koju postižu najbolji modeli: da li ona odražava ograničenje razvijenih arhitektura, ili ograničenje samog zadatka? Odgovor je ključan jer određuje pravac daljeg razvoja. U prvom slučaju bi naprednije arhitekture donele značajan napredak, dok bi u drugom svaki dalji napor bio strukturno limitiran karakterom podataka, a ne modelom.

U cilju ispitivanja ove hipoteze sproveden je ceiling eksperiment u kome je originalni *single-game* target zamenjen centriranim *rolling mean* targetom sa prozorima od 2, 3, 5 i 7 utakmica (Tabela 26). Logika eksperimenta je jednostavna: *single-game* učinak *wide receiver*-a sadrži ogroman udeo nepredvidivog šuma, dok kroz nekoliko uzastopnih utakmica taj šum ima tendenciju da se uprosečuje i ostaje samo signal vezan za objektivni kvalitet i formu igrača. Ukoliko modeli znatno bolje predviđaju izglađeni target, to je direktan dokaz da rezidualna greška na sirovom targetu potiče od ne ublaživog *single-game* šuma, a ne od nesposobnosti modela da nauči strukturu podataka.

Prozor (W)	Test MAE (smooth)	Test R^2 (smooth)	Test MAE (raw)	Test R^2 (raw)
raw target	-	-	18,03	0,3354
2-game	12,10	0,5840	18,48	0,2993
3-game	11,12	0,6018	18,68	0,3114
5-game	8,85	0,7119	19,17	0,2988
7-game	7,73	0,7626	19,41	0,2911

Tabela 26 Rezultati *smoothing* eksperimenata

Rezultati potvrđuju hipotezu na dva nivoa. Kada se isti *LSTM* model evaluira u odnosu na izglađeni target, njegov R^2 raste sa 0,3354 na sirovom targetu do 0,7626 na prozoru od 7 utakmica, dok *MAE* pada sa 18,03 na 7,73 jarda. Ovako dramatičan skok pokazuje da model zapravo veoma precizno razume ko je dobar igrač, kakav mu je dugoročni profil i kakva mu je forma u datom periodu, problem nastaje isključivo kada se traži da tu dugoročnu procenu svede na jedan konkretan meč.

Presudna validacija dolazi iz druge kolone tabele: kada se izglađene (*smooth*) predikcije koriste za evaluaciju nad sirovim (*raw*) *single-game* targetom, R^2 se vraća na vrednosti 0,29-0,34, praktično identične originalnim rezultatima. Drugim rečima, čak i kada raspolaže visokim poznavanjem trenda forme igrača, model ne može da prebaci R^2 prag od 0,33 na pojedinačnoj utakmici. Preostalih približno 0,66 varijanse ciljne promenljive predstavlja strukturno nepredvidiv *single-game* šum. Time se R^2 od 0,33 identifikuje

kao plafon zadatka, a ne plafon razvijenih modela, i potvrđuje da dalje poboljšanje ne može doći iz arhitekturnih ili optimizacionih modifikacija, već isključivo iz uvođenja kvalitativno novih informacija koje redukuju ovaj šum, *real-time* statusa povreda, projekcija broja *snap*-ova, obrazaca odbrambenih formacija ili sličnih izvora signala koji nisu bili dostupni u okviru korišćenog skupa podataka.

Radi obezbeđivanja metodološke korektnosti, *smoothing* je sproveden strogo unutar svakog *split*-a pojedinačno (train, val, test), čime je isključena mogućnost da model pri obučavanju indirektno vidi informacije iz test skupa kroz izračunate pokretne proseke. Dodatna verifikacija sa *per-split smoothing*-om pokazuje razliku u R^2 manju od 0,01, što dokazuje da postignute vrednosti nisu posledica *cross-split* curenja informacija, već realno odražavaju sposobnost modela i objektivnu strukturu problema.

C. Zaključak

U okviru ovog poglavlja razvijen je i sistematski evaluiran skup neuronskih modela za predikciju broja prijemnih jardi *wide receiver*-a na nivou pojedinačne utakmice. Kroz devet sukcesivnih razvojnih faza testirane su različite klase arhitektura: *multilayer perceptron* sa varijantama regularizacije, rekurentne mreže sa *LSTM* i *GRU* ćelijama, dvoulazni *Improved RNN* sa razdvojenim sekvencijalnim i statičkim granama, modeli sa pažnjom i ugrađivanjem identiteta igrača, kvantilna regresija zasnovana na *pinball* funkciji gubitka, kao i ansambl koji kombinuje neuronske i klasične pristupe. Svi modeli su evaluirani pod jedinstvenim protokolom uz striktno hronološku podelu podataka, čime je osigurana uporednost rezultata i isključen rizik od curenja informacija.

Najbolji pojedinačni neuronski model, *LSTM Improved*, postiže $R^2 = 0,3354$ i time nadmašuje sve klasične referentne pristupe u direktnoj evaluaciji, dok *MLP Quantile* q50 ostvaruje najnižu apsolutnu grešku među svim modelima (*MAE* = 17,75 jardi). Najviši ukupni R^2 (0,3384) postiže ansambl *XGBoost* + *LightGBM* + *MLP*, potvrđujući da kombinovanje modela različitih induktivnih pristrasnosti donosi najstabilnije rezultate. Međutim, rezultati najjačih modela obe familije konvergiraju u uski opseg $R^2 \approx 0,33$, što u praktičnom smislu pokazuje da neuronske mreže, iako konkurentne, ne donose dramatičan kvantitativni skok u odnosu na pažljivo podešene *tree* modele na ovom tipu tabularnih podataka.

Ključni metodološki doprinos ovog poglavlja jeste *ceiling* analiza, koja omogućava jasno razlikovanje plafona modela od plafona samog zadatka. Pokazano je da isti modeli, kada se evaluiraju u odnosu na vremenski izglađeni target, dostižu R^2 do 0,76, dok njihova sposobnost predikcije na sirovom *single-game* targetu ostaje ograničena na $R^2 \approx 0,33$ i kada raspolažu informacijama koje bi teorijski trebalo da tu granicu pomere. Ovaj nalaz identifikuje preostalu rezidualnu varijansu kao strukturno nepredvidiv *single-game* šum, a ne kao posledicu ograničenja razvijenih arhitektura. Dodatna ablacija obeležja potvrđuje da već mali podskup najinformativnijih varijabli nosi pretežni deo signala, što potkrepljuje opravdanost primenjene selekcionne strategije.

Konačno, rezultati ostvareni u ovom poglavlju ukazuju na to da neuronske mreže, u kontekstu predikcije učinka *wide receiver*-a na tabularnim podacima, ne pružaju sistematski superiornije performanse u odnosu na klasične modele sa pažljivo konstruisanim obeležjima i vremenskim kontekstom.

Centralni izazov ostaje kvalitet i obim podataka: svaki naredni korak u unapređenju modela nužno podrazumeva značajno proširenje skupa podataka uključivanjem većeg broja sezona, što međutim uvodi i nove metodološke komplikacije, pre svega problem smene era, promena u pravilima igre i evolucije taktičkih sistema, koje narušavaju pretpostavku stacionarnosti raspoređivanja uzoraka kroz vreme. Pored proširenja vremenskog opsega podataka, značajan potencijal leži i u integrisanju dodatnih izvora informacija koji direktno kondicioniraju učinak *wide receiver*-a: podataka o ruti trčanja i pokrivenosti odbrambenih bekova, metrika opterećenja i fizičkog stanja igrača, taktičkih formacija i tendencija napadačke šeme, kao i situacionih faktora specifičnih za NFL kontekst. Američki fudbal je po svojoj prirodi visoko međuzavisan i sistemski složen sport, u kome individualni statistički ishod predstavlja složen ishod međudelovanja brojnih činilaca. Upravo zbog te suštinske složenosti svaki napredak u prediktivnoj preciznosti zahteva ne samo sofisticiranije arhitekture, već pre svega bogatiji i sveobuhvatniji informacioni temelj na kome one počinjavu.

LITERATURA

- [1] Weirich, C., Kim, J.W., Yoon, Y. and Jeong, S., 2025. Advancing NFL win prediction: From Pythagorean formulas to machine learning algorithms. *Frontiers in Sports and Active Living*, 7, p.1638446.
- [2] Mondello, M. and Maxcy, J., 2009. The impact of salary dispersion and performance bonuses in NFL organizations. *Management Decision*, 47(1), pp.110-123.
- [3] Hyndman, R.J. and Athanasopoulos, G., 2018. *Forecasting: principles and practice*. OTexts.
- [4] Elimam, R., Sutton-Charani, N., Prioux, J., Montmain, J. and Perrey, S., 2025. Multi-output regression for the prediction of world-class performances in women's handball. *IEEE Access*.
- [5] Cover, T. and Hart, P., 1967. Nearest neighbor pattern classification. *IEEE transactions on information theory*, 13(1), pp.21-27.
- [6] Breiman, L., 2001. Random forests. *Machine learning*, 45(1), pp.5-32.
- [7] Abadzic, A., Cheun, J. and Patel, M., 2024. Data Analysis on Predicting the Top 12 Fantasy Football Players by Position. *SMU Data Science Review*, 8(2), p.7.
- [8] Pro Football Stats, History, Scores, Standings, Playoffs, Schedule & Records, Available: <https://www.pro-football-reference.com> (accessed Mar. 2026).
- [9] SeleniumHQ, Selenium WebDriver. [Online]. Available: <https://www.selenium.dev/> (accessed Mar. 2026).
- [10] SebastianAndreu, 24679_NFL_WR_Dataset_2025. [Online]. Available: https://huggingface.co/datasets/SebastianAndreu/24679_NFL_WR_Dataset_2025 (accessed Mar. 2026).
- [11] Montgomery, D.C. and Runger, G.C., 2010. *Applied statistics and probability for engineers*. John Wiley & sons.
- [12] Moore, D.S., McCabe, G.P. and Craig, B.A., 2009. *Introduction to the Practice of Statistics* (Vol. 4, p. 641). New York: WH Freeman.
- [13] F. Pedregosa et al., Scikit-learn: Machine Learning in Python. [Online]. Available: <https://scikit-learn.org/stable/> (accessed Mar. 2026).
- [14] Hoerl, A.E. and Kennard, R.W., 1970. Ridge regression: Biased estimation for nonorthogonal problems. *Technometrics*, 12(1), pp.55-67.
- [15] Tibshirani, R., 1996. Regression shrinkage and selection via the lasso. *Journal of the Royal Statistical Society Series B: Statistical Methodology*, 58(1), pp.267-288.
- [16] Zou, H. and Hastie, T., 2005. Regularization and variable selection via the elastic net. *Journal of the Royal Statistical Society Series B: Statistical Methodology*, 67(2), pp.301-320.
- [17] Chen, T. and Guestrin, C., 2016, August. Xgboost: A scalable tree boosting system. In *Proceedings of the 22nd acm sigkdd international conference on knowledge discovery and data mining* (pp. 785-794).
- [18] Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q. and Liu, T.Y., 2017. Lightgbm: A highly efficient gradient boosting decision tree. *Advances in neural information processing systems*, 30.
- [19] Kohavi, R., 1995, August. A study of cross-validation and bootstrap for accuracy estimation and model selection. In *Ijcai* (Vol. 14, No. 2, pp. 1137-1145).
- [20] Bergstra, J. and Bengio, Y., 2012. Random search for hyper-parameter optimization. *Journal of machine learning research*, 13(2).
- [21] Snoek, J., Larochelle, H. and Adams, R.P., 2012. Practical bayesian optimization of machine learning algorithms. *Advances in neural information processing systems*, 25.
- [22] Hochreiter, S. and Schmidhuber, J., 1997. Long short-term memory. *Neural computation*, 9(8), pp.1735-1780.
- [23] Cho, K., Van Merriënboer, B., Gulcehre, Ç., Bahdanau, D., Bougares, F., Schwenk, H. and Bengio, Y., 2014, October. Learning phrase representations using RNN encoder-decoder for statistical machine translation. In *Proceedings of the 2014 conference on empirical methods in natural language processing (EMNLP)* (pp. 1724-1734).
- [24] Rumelhart, D.E., Hinton, G.E. and Williams, R.J., 1986. Learning representations by back-propagating errors. *nature*, 323(6088), pp.533-536.
- [25] Akiba, T., Sano, S., Yanase, T., Ohta, T. and Koyama, M., 2019, July. Optuna: A next-generation hyperparameter optimization framework. In *Proceedings of the 25th ACM SIGKDD international conference on knowledge discovery & data mining* (pp. 2623-2631).
- [26] Nair, V. and Hinton, G.E., 2010. Rectified linear units improve restricted boltzmann machines. In *Proceedings of the 27th international conference on machine learning (ICML-10)* (pp. 807-814).
- [27] Ba, J.L., Kiros, J.R. and Hinton, G.E., 2016. Layer normalization. *arXiv preprint arXiv:1607.06450*.
- [28] Bishop, C.M., 1995. Training with noise is equivalent to Tikhonov regularization. *Neural computation*, 7(1), pp.108-116.
- [29] Zhang, H., Cisse, M., Dauphin, Y.N. and Lopez-Paz, D., 2017. mixup: Beyond empirical risk minimization. *arXiv preprint arXiv:1710.09412*.
- [30] Schuster, M. and Paliwal, K.K., 1997. Bidirectional recurrent neural networks. *IEEE transactions on Signal Processing*, 45(11), pp.2673-2681.
- [31] Bahdanau, D., Cho, K. and Bengio, Y., 2014. Neural machine translation by jointly learning to align and translate. *arXiv preprint arXiv:1409.0473*.
- [32] Koenker, R. and Bassett Jr, G., 1978. Regression quantiles. *Econometrica: journal of the Econometric Society*, pp.33-50.
- [33] Loshchilov, I. and Hutter, F., 2017. Decoupled weight decay regularization. *arXiv preprint arXiv:1711.05101*.
- [34] Huber, P.J., 1992. Robust estimation of a location parameter. In *Breakthroughs in statistics: Methodology and distribution* (pp. 492-518). New York, NY: Springer New York.
- [35] Bergstra, J., Bardenet, R., Bengio, Y. and Kégl, B., 2011. Algorithms for hyper-parameter optimization. *Advances in neural information processing systems*, 24.