

Predviđanje performansi NFL igrača

Milan Jovkić R2 10/2025, Uroš Petrašković R2 9/2025

1. Definicija problema

Potrebno je razviti model za predviđanje budućih performansi NFL igrača. Korišćenjem statističkih podataka o igračima iz prethodnih sezona, model treba da proceni performanse igrača u budućnosti.

2. Motivacija problema rešavanog u projektu

Svaki NFL tim raspolaže istim salary cap-om (ograničenjem plata), zbog čega uspeh tima u velikoj meri zavisi od efikasnog upravljanja budžetom. Timovi koji uspeju da identifikuju igrače sa potencijalom za visoke performanse stiču značajnu konkurentsku prednost. Predviđanje budućih performansi igrača omogućava donošenje kvalitetnijih odluka prilikom formiranja tima, sa ciljem povećanja broja pobeda, čime se povećavaju i šanse za osvajanje titule. Ovaj projekat ima praktičnu primenu kako u profesionalnim NFL klubovima, ali takođe i u fantasy fudbal industriji, čija se vrednost procenjuje na više od 11 milijardi dolara.

3. Relevantna literatura

3.1 "Advancing NFL win prediction: from Pythagorean formulas to machine learning algorithms"- Frontiers in Sports and Active Living

Link: <https://www.frontiersin.org/journals/sports-and-active-living/articles/10.3389/fspor.2025.1638446/full>

Zadatak rada: Evaluacija prediktivnih performansi tradicionalnih i ML modela u predviđanju procenta pobeda NFL timova u datasetu od 2003-2023. Rad poredi Pythagorean expectation formulu sa Random Forrest i Neural Network modelima.

Metodologija: Random Forest regresija i neural network. Kao ulazne promenljive ključni indikatori performansa: points scored i allowed, turnovers, rushing and passing efficiency...

Skup podataka: Podaci prikupljeni sa Pro-Football-Reference.com. Dataset sadrži kompletne team statistike poput passing yards, rushing yards, turnovers, rushing and passing efficiency, penalties...

Evaluacija: Korišćeni su MAE, RMSE i R squared. Neural Network je postigao najbolje performanse (MAE=0.052, RMSE=0.064, $R^2=0.891$), Random Forest je takođe nadmašio tradicionalne metode.

Rezultati: ML modeli su pokazali veću preciznost predikcije u poređenju sa tradicionalnim Pythagorean pristup. Feature importance analiza korišćenjem SHAP

vrednosti identifikovala je points scored i points allowed kao najuticajnije prediktore, dopunjene sa margin of victory i turnover metrikama.

Zaključak za naš projekat: U okviru ovog projekta planiramo primenu algoritama mašinskog učenja, sa posebnim fokusom na Random Forest model, koji je demonstrirao superiornu prediktivnu tačnost u odnosu na klasične statističke metode. Takođe ćemo primeniti feature importance analizu da identifikujemo šta najviše utiče na predviđanje performansi. U daljem proširenju projekta planira se primena neuronskih mreža.

3.2 Elimam et al. (2025) - "Multi-Output Regression for the Prediction of World-Class Performances in Women's Handball"

Link: <https://imt-mines-ales.hal.science/hal-05055721/>

Zadatak rada: Istraživanje efikasnosti multi-output regresionih modela za predviđanje više atletskih i tehničkih performansi elitnih rukometašica na osnovu trening podataka i kontekstualnih faktora.

Metodologija: Rad upoređuje različite modele: kNN, regression tree, random forest i neural networks i to u njihovim single-output i multi-output varijantama, uz dummy baseline koji predviđa prosečnu performansu. Evaluacija je sprovedena hronološkim pristupom, gde podaci iz treninga i prethodnih utakmica služe za predikciju performansi u narednoj utakmici, a preciznost modela je ocenjena korišćenjem metrike average RMSE.

Skup podataka: Dataset obuhvata 533 zapisa sa različitim ulaznim podacima, uključujući IMU senzore (akceleracije, promene pravca, PlayerLoad), anotirane akcije sa video snimaka i osnovne informacije o utakmicama i ulogama igrača. Ciljne promenljive su 7 performansi rukometašica (atletske i tehničke), koje se predviđaju istovremeno pomoću multi-output regresionih modela.

Evaluacija: Modeli su evaluirani hronološkim pristupom, pri čemu su podaci sa treninga i utakmica korišćeni za predviđanje performansi u narednoj utakmici. Preciznost predikcija merena je pomoću average RMSE (aRMSE) metrike, dok je dodatno analizirano i vreme računanja svakog modela.

Rezultati: Multi-output modeli su dali bolju preciznost od single-output pristupa. Najbolje performanse među multi-output modelima postigli su kNN i Random Forest. Multi-output pristup je takođe značajno smanjio vreme računanja.

Zaključak: Multi-output regresioni pristup pokazao se kao efikasno rešenje za simultano predviđanje više međusobno povezanih performansi, uz veću preciznost i kraće vreme računanja. Dobijeni rezultati ukazuju da se isti metod može uspešno primeniti i u domenu NFL analitike, gde su performanse igrača izražene kroz više korelisanih metrika, poput osvojenih jardi i postignutih tačdauna.

3.3 Abadzic et al. (2024) – "Data Analysis on Predicting the Top 12 Fantasy Football Players"

Link: <https://scholar.smu.edu/datasciencereview/vol8/iss2/7>

Zadatak rada: Analiza istorijskih performansi NFL igrača sa ciljem predviđanja top 12 fantasy football igrača po pozicijama, kako bi se unapredilo strateško planiranje draft-a i odluka tokom sezone.

Metodologija: Rad koristi statističku analizu i osnovne modele predikcije performansi igrača. Fokus je na integraciji istorijskih podataka i kontekstualnih faktora koji utiču na performanse. Specifični ML algoritmi i metrike nisu detaljno navedeni.

Skup podataka: Dataset obuhvata više pozicija (QB, RB, WR, TE) i performanse igrača kroz prethodne sezone. Podaci su organizovani po pozicijama, što omogućava poziciono-specifičnu analizu.

Evaluacija: Predikcije su poređene sa stvarnim rezultatima fantasy poena kako bi se procenila korisnost modela za donošenje odluka u fantasy fudbalu.

Rezultati: Pristup omogućava korisnicima da bolje planiraju draft i upravljanje fantasy timovima. Analiza ističe značaj istorijskih performansi i pozicionih karakteristika igrača pri donošenju odluka.

Zaključak za naš projekat: Rad ističe značaj poziciono-specifičnog modelovanja, što znači da se performanse igrača analiziraju i predviđaju zasebno za svaku poziciju (QB, RB, WR, TE), jer različite pozicije imaju različite ključne metrike i uticaje na igru. U našem projektu koristićemo ML tehnike kako bismo predvideli stvarne performanse igrača (yards, touchdowns), a ne fantasy poene, čime ćemo preciznije oceniti njihove individualne sposobnosti i doprinos timu.

4. Skup podataka

Većinu podataka skupljamo sami sa izvora poput ProFootballReference sajta, dok manji deo podataka preuzimamo sa platforme HuggingFace, (dataset SebastianAndreu/24679_NFL_WR_Dataset_2025), koji obuhvata podatke za wide receiver poziciju u period od 2015. do 2025. godine. Za ostale pozicije nismo uspeli da pronadjemo podatke u adekvatnom formatu i zato većinu podataka prikupljamo sami. U ovu svrhu koristi se scraper napravljen u pythonu koji sakuplja podatke sa pro football reference sajta i od njih pravi CSV fajlove.

Za kvoterbekove, ciljna promenljiva u modelu biće passing yards. Skup podataka sadrži kombinaciju standardnih i advanced promenljivih koje zajedno opisuju performanse igrača tokom sezone. Standardne promenljive obuhvataju osnovne statistike i agregirane pokazatelje učinka, kao što su: *Season, Age, Team, Pos, G, GS, QBrec, Cmp, Att, Cmp%, Yds, TD, TD%, Int, Int%, 1D, Succ%, Lng, Y/A, AY/A, Y/C, Y/G, Rate, QBR, Sk, Yds_Lost, Sk%, NY/A, ANY/A, 4QC, GWD, AV i Awards*. Pored toga, koriste se i advanced promenljive koje detaljnije opisuju kvalitet dodavanja i ponašanje kvoterbeka pod pritiskom, uključujući metrike kao što su: *pass_target_yds, pass_air_yds, pass_yac, pass_drops, pass_poor_throws, pass_on_target, pocket_time, pass_pressured, rush_scrambles*, kao i statistike vezane za *RPO* i *play-action* situacije. Ove promenljive omogućavaju dublji uvid u efikasnost i stil igre kvoterbeka, čime se poboljšava kvalitet predikcije ciljne promenljive.

Kada gledamo running backove i wide receive ciljna promenljiva će biti jardi, rushing yardi za running backove, receiving yardi za wide receiver. Skup podataka sadrži promenljive poput: jardi po istrčanoj ruti, jardi posle kontakta, yardi na play action pasevima i mnoge mnoge druge vrednosti. Za hvatače lopte tj. Wide receive imamo čak 98 kolona u data setu.

Ovaj sport je komplikovan, treneri i igrači provode nezamislivo mnogo vremena proučavajući protivničke taktike ne bi li nešto razotkrili, ima gomila varijabli, performans svakog igrača je uvezan sa performansima drugih igrača sopstvenog pa čak i protivničkog tima, baš zato je teško izolovati pojedinačnog igrača od svog okruženja. Upravo zato je od ključnog značaja prikupiti što je moguće više relevantnih podataka, uključujući i advanced promenljive, kako bi se modeli što više približili realnom i pouzdanom predviđanju performansi.

5. Metodologija

U okviru projekta planira se primena algoritama mašinskog učenja za predviđanje višedimenzionalnih performansi NFL igrača. Proces će početi analizom i predprocesiranjem podataka, koja uključuje detekciju i tretman outliera, rad sa nedostajućim vrednostima, normalizaciju i skaliranje numeričkih atributa, kao i eventualnu enkodaciju kategorijalnih promenljivih.

Za modelovanje performansi planira se korišćenje različitih regresionih algoritama, počevši od jednostavnijih modela poput linearne regresije, zatim uključujući regularizovane regresije (Ridge, Lasso, ElasticNet) i KNeighborsRegressor. Kao glavni model predviđa se Random Forest regresija, zbog svoje sposobnosti da efikasno rukuje višedimenzionalnim i koreliranim ciljevima. Planira se kreiranje posebnog modela za svaku poziciju, pri čemu će primarna ciljna promenljiva biti yardi (rushing yards, passing yards, reception yards itd.). U daljem proširenju projekta predviđa se primena multi-output regresije, kako bi se analiziralo kako model reaguje pri simultanom predviđanju više performansi igrača. Takođe kao proširenje planira se primena neuronskih mreža. Performanse svih korišćenih metoda biće analizirane i upoređivane u istraživačke i akademske svrhe radi odabira najefikasnijeg pristupa.

6. Metod evaluacije

Za evaluaciju modela dataset će biti inicijalno podeljen na trening i test skup, pri čemu će podaci iz prethodnih sezona i utakmica služiti za treniranje, a modeli će predviđati performanse u narednim utakmicama. Pored podele na trening i test skup, koristiće se i validacioni skup u okviru trening podataka radi optimizacije hiperparametara modela. Optimizacija će se sprovoditi primenom k-fold cross-validation metode. Planira se evaluacija posebnih modela za svaku poziciju, pri čemu će se u početku fokusirati na predviđanje yardi, dok će se u daljem proširenju koristiti multi-output regresija za simultano predviđanje više performansi igrača. Različiti algoritmi, uključujući linearnu regresiju, Ridge, Lasso, ElasticNet, KNeighborsRegressor, Random Forest i u proširenju neuronske mreže, biće testirani kako bi se uporedile njihove performanse u predviđanju ciljnih metrika.

Preciznost modela biće kvantifikovana korišćenjem standardnih regresionih metrika: MAE, RMSE i R^2 .